

# 間取り図に基づく類似性抽出

佐嘉田悠樹<sup>†</sup> 伊東 栄典<sup>††</sup>

<sup>†</sup> 九州大学 システム情報科学府 〒 819-0395 福岡市西区元岡 744

<sup>††</sup> 九州大学 情報基盤研究開発センター 〒 819-0395 福岡市西区元岡 744

E-mail: <sup>†</sup>y.sakata.222@s.kyushu-u.ac.jp, <sup>††</sup>ito.eisuke.523@m.kyushu-u.ac.jp

あらまし 近年, FinTech のように IT 導入が各業界へ波及している. 不動産業界でも「不動産テック (Real Estate Tech: ReTech)」が注目されている. 日本の不動産業界は, 取引の不透明性や複雑な制度によりデジタル化が妨げられていたものの, 法改正や不動産ベンチャーの参入増大など徐々に緩和の動きがある. 不動産テックの普及により, 情報量の増大, 取引の活性化, ビッグ データ活用の実現, さらに潜在需要の掘り起こしの可能性がでてくる. 現在, 日本の不動産情報サイトは各不動産管理会社入力 of 文字情報を検索できる. しかし画像情報は検索できない. 入力欄が有る文字列情報と異なり, 間取り図は不動産管理会社独自の形式で作成されており互換性が無い. 本稿では, 間取り図を検索する手法を取り扱う. 本研究では検索クエリとして利用者が間取りを想定して組み立てたブロック模型の写真を与え, 類似する間取り図画像を表示する手法を考える. Deep CNN モデルの VGG16 を用いて, 間取り図画像とクエリ画像を転移学習させる. 続いて, VGG16 から特徴量を抽出し, CNN でクエリ画像と間取り図画像の一致・不一致を学習させて, Siamese Network を構成する. 最後に, 間取り図と模型写真の類似度を算出する.

キーワード 不動産, 間取り図, 類似度検索, ビッグデータ, データマイニング, 画像処理, Siamese Network, 深層学習, 機械学習, CNN, VGG16

## 1 はじめに

近年, 経済界での FinTech に代表される IT 導入が, 各業界へ波及している. 不動産業界でも, テクノロジー活用「不動産テック (Real Estate Tech: ReTech)」が注目されている [1]. とりわけ日本の不動産業界は, 取引の不透明性や複雑な制度によりデジタル化が妨げられていたものの, 法改正や不動産ベンチャーの参入増大など徐々に緩和の動きがある. 不動産テックの普及によって, 情報量が増大し, 取引が活性化し, ビッグデータ活用が可能となり, さらに潜在的な需要を明らかにする可能性がある.

現在, 日本の不動産情報サイトは各不動産管理会社がそれぞれ入力した文字情報について, 利用者が検索することができるものの, 画像情報を検索に用いることができない. 各入力欄が用意されている文字列情報と異なり, 特に間取り図は各不動産管理会社が各々の形式で作成しているため, 互換性がない. そのため, 利用者は入力された文字列情報 (部屋数・設備・面積) などから検索して類推することが強いられている.

本稿では, 間取り図画像を対象に検索可能にする手法について取り扱う. 本研究では検索クエリとして利用者が間取りを想定して組み立てたブロック模型の写真を与えて, 類似した間取り図画像を表示できるシステムを考える. Deep CNN モデルの VGG16 を用いて, 間取り図画像とクエリ画像についてそれぞれ転移学習させる. 続いて, それぞれの VGG16 から特徴量を抽出して, CNN でクエリ画像と間取り図画像の一致・不一致を学習させる.

2 章では, 間取り図の画像を対象に, 多様な形式を同一の形

式で扱えるように機械的処理を行う手法についての研究を 3 編紹介する. 3 章では, 本研究の目的と手法について取り上げる. 最後に学習モデルを評価手法についても取り上げる. 4 章では, 実際に行った実験手順と, 結果の概要について取り上げる. 今回の実験では間取り図画像の前処理と学習, 模型写真の学習, 学習モデル特徴量同士の学習について取り上げる. 5 章では, 今後の研究の方針について示す.

## 2 関連研究

本研究の提案手法に関連する先行研究を述べる. まず, 間取り図から情報の抽出を行い, 部屋の自動検出および部屋の自動ラベリングを行う手法について提案している文献 [2] を紹介する. 間取り図に対して 3 段階の処理を行い, 部屋へラベリングを行っている.

次に, 間取り図と室内の写真の自動対応付けについて研究している文献 [3] を紹介する. 間取り図と写真との間での類似性を求め, 間取り図に対応する写真のマッチングや, 間取り図の中で対応する領域の可視化を行っている.

最後に間取り図同士の構造的類似度を求める手法について提案している文献 [4] を紹介する. 間取り図とメタデータから間取りや部屋の有無などについて深層学習を行い, 入力に類似する間取り図を提示させている.

### 2.1 間取り図画像からの構造抽出・ラベル抽出

Ahmed ら [2] [5] は, 間取り図から部屋を検知して自動でラベリングする手法について研究している. 白黒 2 色の間取り

画像に対して、情報的セグメンテーション (Information Segmentation), 構造的解析 (Structural Analysis), 意味論的分析 (Semantic Analysis) の3段階の処理を行い、部屋ヘラベリングを行う手法を提案している。

情報的セグメンテーションでは画像から文字列領域の抽出、直線の抽出、線の太さによる分類など画像的な処理を行っている。構造的解析では線の情報に基づいた、壁の抽出、部屋の領域の決定など図形的な処理を行っている。意味論的分析では、文字列の抽出、扉や窓のシンボル抽出、部屋のラベリングなど意味に基づいた処理を行っている。

2,479 × 3,508, 80 枚の間取り図画像を用いて評価実験をしたとき、部屋の認識精度は意味論的分析を用いていない手法 [6] を上回る結果を得られている。このため、文字列の抽出などの意味論的分析は認識精度の向上に効果がある。

## 2.2 間取り図画像と部屋の写真の対応付け

Chen ら [3] は、部屋の内装の写真と間取り図画像との異なる種類の画像を対応手法を実験している。間取り図と写真との間での類似性を求め、間取り図に対応する写真のマッチングや、間取り図の中で対応する領域の可視化を行っている。

写真と間取り図の対応をさせるクロスモーダル画像マッチング問題を解決するために以下のような手順で行う。まず、ニューラルネットワーク (VGG16) を用いて各写真、間取り図の画像について学習させる。次に、VGG16 のベクトルの連結をして完全連結回帰ネットワークからシヤムネットワーク (Siamese Network) を構築して類似度を学習させる。これを部屋の種類を区別せず学習させた場合、部屋の種類 (台所、浴場、居間) ごとに写真を学習させた場合、部屋の写真のセット (台所、浴場、居間の各ベクトルの連結) で学習させた場合について、間取り図のマッチングでの類似度を評価している。類似度を用いて逆に間取り図に一致する内装写真の分類をさせる実験も行っている。

結果としては、いずれの実験においても高い精度を記録し、いずれの場合でも人間の手作業 (Amazon Mechanical Turk) によるものより高い結果を出している。このため、形式が全く異なる種類の画像であってもシヤムネットワークの深層学習で、人間より高い精度での対応付けができています。

また、さらに実装モデルが写真の中の物体を認識しているのかを検証するために、写真を加工編集して影響を見た。間取り図と写真に対して PatchMatch を用いて、洗面台を取り除いて Pair Matching で実験を行った。結果として対応する画像に対して類似性の高いスコアが出たため、モデルは写真の中の物体を認識して対応付けが検証された。

## 2.3 間取り図画像と文字列情報を用いた類似間取り図画像の抽出

Takada ら [4] は、従来の間取り図画像の教師あり学習でのセマンティックセグメンテーションの手法 [7] を簡易化するために、不動産メタデータ (文字列情報) と間取り図画像を用いてディープニューラルネットワーク学習を行い、間取り図画像の

間取りタイプ自動分類・部屋の有無の自動判定を行う手法を提案している。さらにこの2つを組み合わせると類似する間取り図の提案する手法を研究している。

間取りのグラフ構造類似度  $p$  以上の画像を正解として、評価手法には precision@5 (検索結果上位 5 件のうち正解データが含まれる割合) を用いて実験している。20140 枚の画像を用いて学習を行い、2000 枚の画像に対してテストを行っている。出現数の多い間取りタイプの正答率が高く、間取りタイプの差が少ないものは低くなっている。部屋の有無の自動判定では情報量が少ない部屋の精度が低くなっている。間取り図の提案では間取りタイプのみ、部屋の有無のみの場合よりも、組み合わせた提案手法のほうが高い精度を出している。このため、間取り図タイプ、部屋の有無など複数の種類のラベリングを用いた学習が効果がある。

## 3 研究の目的

本研究 [8] では間取り図画像を検索するために、利用者の想定した間取り構造から間取り図を検索する手法を提案する。今回、利用者は間取り構造イメージを表現するためにブロック模型で構造を作成する。ブロック模型は専門のソフトウェアと違って操作を覚える必要がないため作成がしやすく、描画と違ってある程度均質な形式に揃えることができるため、今回の研究では採用した。作成されたブロック模型を上部から撮影し、写真をクエリとして入力する (図 1)。クエリをもとに間取り図の検索を行い、利用者の意図した部屋の間取り図を出力することをできるシステムを想定する。検索システムを実現するための手順について以下で説明する。(図 2)




図 1 ブロック模型の写真例

### 3.1 前処理

まず、学習に用いるデータを用意する。不動産情報サイトから各物件について間取り図と文字情報を取得する。文字情報には間取り (1DK, 2LDK など)、面積、設備などが含まれる。

次に、間取り図の前処理を行い、間取り図を同一の学習モデルで扱いやすい形式に整形する。間取り図画像に含まれる、ファイル圧縮の過程で混入したノイズ、不動産会社によって異

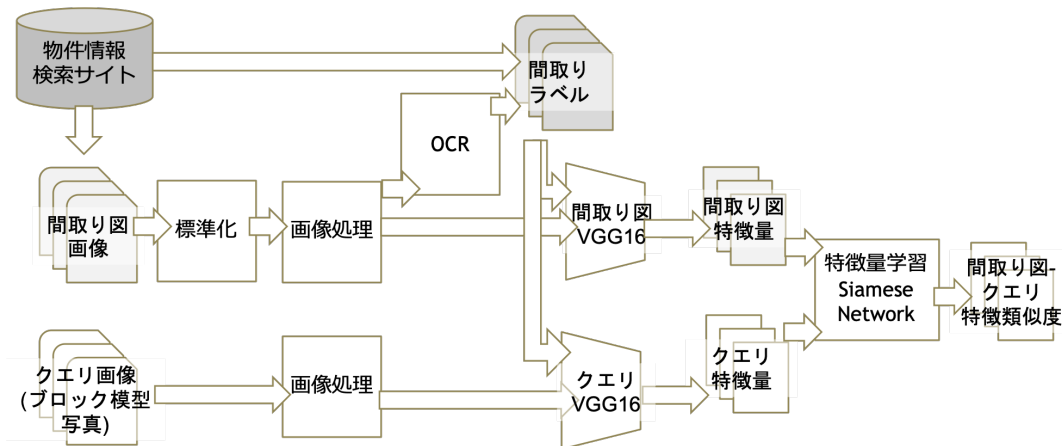


図 2 実験の流れ

なるフォント，色，部屋の構造などの特徴を考慮した処理を行う。この処理は，色の置換，文字抽出，支配色ポスタライゼーション (Dominant Color Posterization)，明度調整，コントラスト調整，平滑化，正規化，ZCA Whitening，ぼかしなどを組み合わせる。続いて，手作業で各間取り図に対応したブロック模型を作成し撮影して訓練用データを用意する。

取得した各間取り図について象ったブロック模型を制作する，ブロック模型を明度，向きなどによって複数の条件で写真を撮影して学習に用いるデータとする。この写真についても光源の明るさやノイズなどを考慮した前処理を行い，学習しやすい形式に整形する。

### 3.2 画像学習

次に，間取り図に Python ライブラリ Keras の DeepCNN 学習済みモデル VGG16 を用いて，不動産情報サイトから取得した間取り図に対応した間取り・部屋の有無などを学習ラベルとして転移学習を行う。同様に写真クエリについても同様の学習ラベルを用いて VGG16 で別途転移学習を行う。間取り図および写真クエリを学習した各 VGG の学習層のベクトルを抽出して，間取り図の特徴量および写真クエリの特徴量とする。これによって画像情報をベクトルとして扱えるようにする。

### 3.3 特徴量学習

その次に，間取り図と写真クエリの各特徴量を用いて CNN を用いて学習を行い，Siamese Network (シヤムネットワーク) [9] を作成する。一般的に間取り図の構造の学習にはグラフ構造やセマンティックセグメンテーションなどの教師データを用いる場合が多いが，Siamese Network では学習済みモデルの特徴量間の距離を用いた学習で構造類似性を学習できる。学習ラベルとしては間取り図と写真クエリの一致 (1) / 不一致 (0) を学習させる。これによって間取り図と写真クエリについての類似度を計算できるようになる。(図 3)

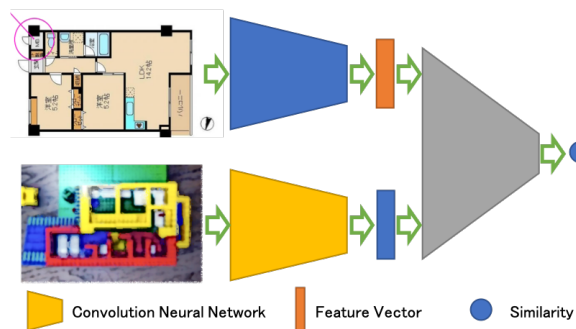


図 3 Siamese Network

できる。例えば，このシステムに対して利用者が新たなブロック模型写真を与えたとき，既存の間取り図との類似度の計算によって，最も類似した間取り図を検索できる。

### 3.4 検索システムの評価

最後に，訓練用データ以外の検証用の写真クエリの特徴量を学習モデルに与えて，対応する間取り図の類似度が高くなるかを検証する。

## 4 実験

### 4.1 実験データ

実験用のデータとして間取り図を用意する必要がある。今回，実験データとして SUUMO<sup>1</sup>と LIFULL HOME'S<sup>2</sup>の Web ページ，および LIFULL HOME'S のデータセット [10] が候補として存在した。表 1 に 3 つの仕様について示す。3 つのデータの比較の結果，間取り図の画像サイズが最も大きい SUUMO の Web ページを用いて，まず実験 1～3 を行うことに決定した。

物件情報検索サイト SUUMO をスクレイピングして福岡市西区の物件から間取り図画像 1702 件および付属する文字情報

3.1～3.3 で述べた手順で検索システムを実現することが

1 : <https://suumo.jp/>

2 : <https://www.homes.co.jp/>

を取得し、以下実験データとして用いる。

また、実験4～6については大規模なデータが必要となったため、LIFULL HOME'S データセットを用いることにした。公開されているデータセットの一部である1,569,385件を実験に用いた。

#### 4.2 実験1：間取り図画像の処理と学習

実験データの間取り図画像に色の置き換えの処理 (Col Ex) を適用して整形を行った。比較対象として元のデータのまま実験を行うものも用意した。

その後、間取り図画像を間取りに応じて1706枚22クラス、部屋数に応じて972枚4クラスに分類して実験を行う。訓練用データ (Training) と検証用データ (Validation) に分割した。学習データ・バリデーションデータの分割比 (Val : Trn) の比較として、0.2 (学習データ80% : バリデーションデータ20%)、0.5 (学習データ50% : バリデーションデータ50%) の2通りを行った。

バッチ学習時の画像拡張処理の比較 (以下の2種類) として、A (変形) : Shear (引き伸ばし) / Zoom (拡大・縮小)、B (反転 + 変色) : Flip (反転) / Channel Shift (色温度変化) / Standard Normalization (正規化)、の2通りを行った。

Imagenet を用いたもの、学習モデルの重みを用いなかったものの比較を行って転移学習をさせた。Epoch 数200、バッチサイズ32、オプティマイザSGD、学習率0.0001で条件を揃えて実験を行う。

学習済みモデルVGG16を転移学習して学習を行い、検証用データでの結果をLossとAccuracyを評価した。

#### 4.3 結果 1

結果は表3の通りとなった。VGG16のWeightにImagenetを用いた場合はNoneよりAccが高いが過学習も起きやすい。画像拡張にAよりBを用いた方がVal Accuracyが高い。画像の前処理としてCol Exを用いたものはVal lossが高い結果になった。このためVal lossを下げるように学習率とEpoch数を調整して実験する必要がある。

#### 4.4 実験2：模型写真の学習

間取り図を象ったブロック模型を撮影して学習させる。SUUMOの間取り図12枚に対して、ブロック模型で同じ構造を各1つ制作した。撮影台を用いて、ブロック模型を条件・向きを変えた16通りを撮影して、合計192枚の写真を得て学習用データとした。実験1と同様の学習ラベルを用いてVGG16モデルの転移学習を行った。

#### 4.5 結果 2

学習データが少ないため実験1と比較して高い精度の結果が得られた。ただし、汎化性能が低いため改善の余地がある。

#### 4.6 実験3：間取り図と模型写真の特徴量の学習

間取り図の特徴量と模型写真の特徴量を入力として、各ペアでの対応関係を2値ラベルとして、CNNで学習させてSiamese

Networkを構築する。実験1の間取り図の学習モデル、および実験2の模型写真の学習モデルを用いて、間取り図および模型写真の特徴量を抽出する。本実験では各モデルの特徴量として隠れ層である全結合層fc6の1024次元を入力に用いる。Siamese FaceNet [11] を転移学習させ、各特徴量を用いたSiamese Networkを構築する。12枚の間取り図と196枚の模型写真のペアを一致(1) / 不一致(0)を学習ラベルとして与えて、CNNを用いて学習させた。

#### 4.7 結果 3

学習の結果、学習データについては高い精度が得られた。ただし、テストデータに関しては精度が低く、汎化性能が低い。各サンプルについて結果を確認したところ、類似度の高い結果は間取り図同士の色相に類似に見られるため、目的の構造による学習ではなく色による学習を行っている可能性がある。間取り図が12枚の少ないサンプルによって学習させているため、過学習していると考えられる。

#### 4.8 実験4：大規模データセットを用いた間取り図の学習

実験3について汎化性能が低くなっている原因を取り除くために、学習データを増やし汎化性能の向上を図る。LIFULL HOME'S データセットから一部の2,361,344件の間取り図画像について実験1と同様に学習させて、特徴量に変換できるようにする。

SUUMOのラベルとLIFULL HOME'S データセットのラベルの形式が異なるため、今回は11ラベル (和室、洋室、DK, LDK, L, D, K, その他, LK, LD, S) を用いて学習させた。実験1の結果の良かったB (反転 + 変色) : Flip (反転) / Channel Shift (色温度変化) / Standard Normalization (正規化) で画像拡張させて、VGG16を転移学習させた。バッチサイズ512、10epochで実験した。

#### 4.9 結果 4

11ラベル (和室、洋室、DK, LDK, L, D, K, その他, LK, LD, S = ラベル番号2～12) それぞれについて学習させた。epoch数が少ないためラベルによっては学習が完了せず精度が高くなっていないものもある。図5のグラフではepoch10時点で下から順にL (6)、洋室 (3)、DK (5)、LDK (4)、S (12) は学習精度が低い。L (リビング)、DK (ダイニング・キッチン)、LDK (リビング・ダイニング・キッチン) については、これらのうちいずれか1つは多くの物件に付属しているが、間取り図では文字を読み取らないと区別が付きにくい。そのため区別できなかった可能性がある。洋室は多くの物件に付属するが、他のラベルと違って特徴となるものが少ないため区別がつかなかった可能性がある。S (サービスルーム) はウォークインクローゼットや納戸や収納など種類が様々あり学習できなかった可能性がある。

#### 4.10 実験5：模型写真の学習 (2)

実験4にそって、ブロック模型写真の学習のラベルについても11ラベルで学習を行う。実験2に用いたSUUMOの間取

表 1 実験データ

	SUUMO Web ページ	LIFULL HOME ' S Web ページ	LIFULL HOME ' S データセット
物件数	650 万	770 万	530 万
間取り図画像サイズ	800x800 以内	568x426 以内	120x120 以内
画像ファイル取得	スクレイピング	スクレイピング	NII 提供
メタデータ取得	スクレイピング	スクレイピング	NII 提供
時期	最新	最新	2015 年 9 月時点

表 2 実験 1:VGG16 による間取り図の学習結果

画像処理	画像拡張	Weights	Ctgr	Val:Trn	Loss	Acc	Val loss	Val acc
None	A	Imagenet	22	0.2	0.4477	0.8628	1.2566	0.6167
None	B	Imagenet	22	0.5	0.2713	0.918	0.7931	0.7746
Col Ex	B	None	22	0.2	2.2588	0.1966	2.2362	0.1833
None	A	None	4	0.2	0.8997	0.6927	0.8939	0.6987
None	B	None	4	0.2	0.9124	0.6906	0.8501	0.716
Col Ex	B	None	4	0.2	1.1707	0.4234	1.1725	0.4321

表 3 実験 2:VGG16 による間取り図の学習結果

画像処理	画像拡張	Weights	Ctgr	Val:Trn	Loss	Acc	Val loss	Val acc
None	B	None	3	0.2	0.8114	0.7049	0.8328	0.6923





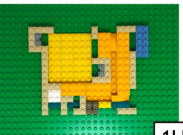







入力	予測 1 = 正解	予測 2	予測 3
	 1LDK 0.79642284	 1LDK 0.56309044	 2LDK 0.56079453
	 1LDK 0.9700982	 1LDK 0.9040155	 2LDK 0.79645157
	 2LDK 0.7080139	 2LDK 0.54351175	 3LDK 0.24931028

図 4 実験 3:Siamese Network による学習結果




図 5 実験 4:間取り図学習の accuracy 変化

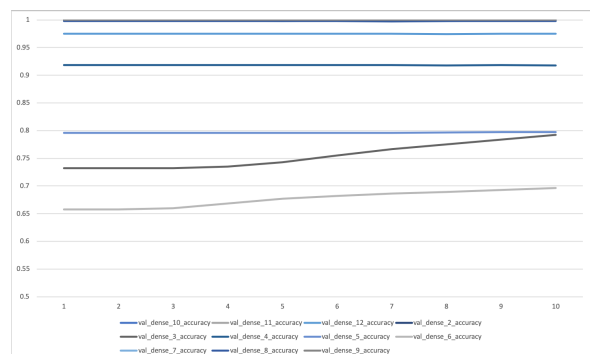


図 6 実験 4:間取り図学習の validation accuracy 変化

り図 12 枚に対応するように LIFULL HOME'S 形式の 11 ラベル (和室, 洋室, DK, LDK, L, D, K, その他, LK, LD, S) を手作業でラベル付けした。同様に合計 192 枚の写真について

ラベルを振り分けた。同様に VGG16 を転移学習させた学習モデルを用いて学習させた。epoch 数は 100 で実験を行った。



#### 4.11 結果 5

実験 4 と同様に 11 ラベルそれぞれについて学習させた。図 7 の通り、100epoch 時点で accuracy が低い順に和室（2）、S（12）、LD（11）となっている。LD については epoch に伴う向上が見られるが、和室・S については向上が見られない。実験データとなるブロック模型が少ないため、データ数を増やした場合には精度の向上が見込まれる。




図 7 実験 5:模型写真学習の accuracy 変化




図 8 実験 5:模型写真学習の validation accuracy 変化

#### 4.12 実験 6：間取り図と模型写真の特徴量の学習

実験 4 で学習させたモデルが汎化性能を高めたのであるかを検証するために、実験 3 と同様にシャムネットワークを構築して学習させる。

実験 4 の LIFULL HOME'S 間取り図の学習モデル、および実験 5 の模型写真の学習モデルを用いて、間取り図および模型写真の特徴量を抽出する。本実験で各モデルの特徴量として隠れ層である全結合層 fc6 の 1024 次元を入力に用いる。Siamese FaceNet [11] を転移学習させ、各特徴量を用いたシャムネットワークを構築する。SUUMO の 1794 枚の間取り図と 196 枚の模型写真のペアを 800 ペア作り、一致 (1)：不一致 (0) = 1：4 の学習ラベルとして与えて、CNN を用いて 200epoch で学習させた。

#### 4.13 結果 6

図 10 のように学習データに対して 95%の精度で学習ができている。loss は下がっている（図 10）がテストデータでの精度が上がっていないため、学習が足りていない可能性がある。図

11 の通り、色の関係ないものが類似している候補として挙げられているため、色以外の要素を学習していると見られる。図中の下段はすべて 2LDK が列挙されているため意図した通りの学習ができている。上段と中段は 1LDK の入力に対して 1LDK 以外が候補として挙げられているため、他の要素を学習した可能性がある。上段はいずれも洋室を 1 室以上持つため、洋室の数を学習して類似度が高くなっている可能性がある。中段は入力と予測 2 は 1LDK で同じだが、予測 3 の 2LDK は和室を含まないため何が類似度を高くしているのか今後の課題となる。




図 9 実験 6:シャムネットワーク学習の accuracy 変化

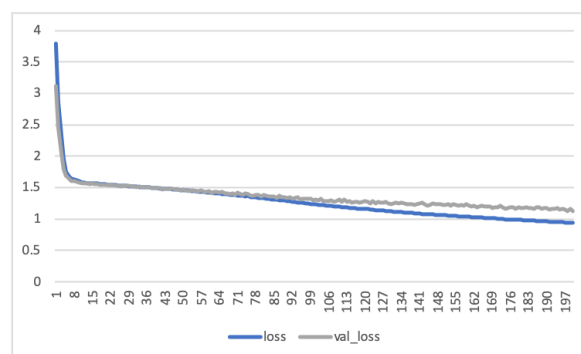


図 10 実験 6:シャムネットワーク学習の loss 変化

## 5 おわりに

ICT 及び ReTech の進展に伴い、文字や数値以外の情報を不動産サービスに用いることが検討されている。本研究では不動産物件の間取り図に着目し、ブロック模型で作る間取り図写真に類似した物件を抽出することの実現を目指す。

本稿では関連する先行研究を調査した結果を述べた。また我々が提案する類似物件検索システムの実現手法について述べた。ブロック模型を用いて、使用者が入力をする想定で、類似度を算出して、検索結果を出力できるようにする。

収集したデータを用いた前処理、間取り図画像とラベルの学習を行った。ブロック模型を制作し、撮影した写真とラベルの学習を行った。間取り図の学習モデルとブロック模型写真の学習モデルを用いて、画像の対応関係を学習させた。

入力	予測 1 = 正解	予測 2	予測 3
 1LDK	 0.8874394 1LDK	 0.8517206 2LDK	 0.7775366 2LDK
 1LDK	 0.8912035 1LDK	 0.77178407 1LDK	 0.612012 2LDK
 2LDK	 0.9173422 2LDK	 0.8678993 2LDK	 0.85825217 2LDK

図 11 実験 6: シヤムネットワークによる学習結果

今後、ブロック模型の学習データの件数を増加させて学習精度の向上の図った後、類似度を用いた検索システムの実装後、検索精度の検証を行う。

## 謝 辞

本研究では、株式会社 LIFULL が国立情報学研究所の協力により研究目的で提供している「LIFULL HOME'S データセット」を利用した。

## 文 献

- [1] Y. Kiyota, T. Yamasaki, H. Suwa, and C. Shimizu, "Real estate and AI," *Artificial Intelligence*, vol. 32, no. 4, pp. 529–535, 7 2017.
- [2] S. Ahmed, M. Liwicki, M. Weber, and A. Dengel, "Automatic room detection and room labeling from architectural floor plans," *2012 10th IAPR International Workshop on Document Analysis Systems, Gold Cost, QLD*, pp. 339–343, 2012.
- [3] C. Liu, J. Wu, P. Kohli, and Y. Furukawa, "Deep multi-modal image correspondence learning," arXiv: 1612.01225, Tech. Rep., 2016.
- [4] Y. Takada, N. Inoue, T. Yamasaki, and K. Aizawa, "Similar floor plan retrieval featuring multi-task learning of layout type classification and room presence prediction," *2018 IEEE International Conference on Consumer Electronics (ICCE), Las Vegas, NV*, pp. 1–6, 2018.
- [5] S. Ahmed, M. Liwicki, M. Weber, and A. Dengel, "Improved automatic analysis of architectural floor plans," in *Proceedings of the International Conference on Document Analysis and Recognition, ICDAR*, 2011, pp. 864–869.
- [6] S. Macé, H. Locteau, E. Valveny, and S. Tabbone, "A system to detect rooms in architectural floor plan images," *ACM International Conference Proceeding Series*, pp. 167–174, 06 2010.
- [7] 大原康平, 山崎俊彦, and 相澤清晴, "間取りや広さをクエリとす

る直感的な不動産検索システム," 情報処理学会第 78 回全国大会, 5Y-08, 2016.

- [8] 清田陽司, 山崎俊彦, 諏訪博彦, and 清水千弘, "エディトリアル不動産と ai (特集 不動産と ai)," *人工知能 : 人工知能学会誌 : journal of the Japanese Society for Artificial Intelligence*, vol. 32, no. 4, pp. 529–535, jul 2017. [Online]. Available: <https://ci.nii.ac.jp/naid/40021258997/>
- [9] G. Koch, R. Zemel, and R. Salakhutdinov, "Siamese neural networks for one-shot image recognition," *ICML Deep Learning Workshop. Vol. 2*, 2015.
- [10] 情報学研究データリポジトリ LIFULL HOME'S データセット. [Online]. Available: <https://www.nii.ac.jp/dsc/idr/lifull/>
- [11] X. Chen. keras-face. [Online]. Available: <https://github.com/chen0040/keras-face>