

半教師あり学習を用いた雲の種類と状態の分類

顧 席銘[†] 森川 優[†] 稲村 直樹^{††} 小渕 浩希^{†††} 大島 裕明[†]

[†] 兵庫県立大学 大学院応用情報科学研究科 〒650-0047 兵庫県神戸市中央区港島南町 7-1-28

^{††} バニヤン・パートナーズ株式会社 〒650-0034 兵庫県神戸市中央区京町 72

^{†††} スカパー JSAT 株式会社 〒107-0052 東京都港区赤坂 1-8-1

E-mail: [†]{aa19z502,ab19f501,ohshima}@ai.u-hyogo.ac.jp, ^{††}inamura@banyanpartners.co.jp,

^{†††}obuchi-hiroki@sptvjsat.com

あらまし 本研究では、スマートフォンなどで撮影した空の画像から、そこに写っている雲の種類や雲の状態を認識する問題に取り組む。雲画像の分類問題においては、雲の種類や雲の状態を判別することは専門家によってしか行うことができない。一方で、雲画像は容易に大量に撮影することが可能である。そこで、ラベルがつけられていない雲画像を利用して分類を行う手法を提案する。提案手法では、まず、ラベルがつけられている雲画像を用いて分類モデルを構築する。その後、ラベルがつけられていない雲画像の分類を行い、そのうち、確信度高く分類できた画像を選択し、もともとラベルがつけられている雲画像とそれらを用いて新たに分類モデルを構築するというを行う。

キーワード 雲画像分類, ディープラーニング, 半教師あり学習

1 はじめに

雲は気象状況を判断するための重要な要素であるといえる。雲の種類が異なると、天気と与える影響も異なる。インターネットでは雲の種類情報は提供されているが、一般の人々が実際に雲を見て、雲の種類を判別することは難しい。気象の専門家であれば、雲の特徴に基づいて雲の種類を判別することができる。そして、実際に、雲の種類情報は気象予報などで利用されている。

雲の画像から雲の種類を自動的に判別することができれば、気象の専門家にとって有用であるばかりでなく、ビッグデータ時代において社会に有用な情報を提供することができるようになり、社会的意義があると考えられる。そこで、本研究では、スマートフォンなどで撮影した空の画像から、そこに写っている雲の種類や雲の状態を認識する問題に取り組む。

本研究で用いるデータは、スカパー JSAT 株式会社によって提供されている「くもろぐ」というスマートフォンアプリケーションにおいてユーザから提供された画像データである。「くもろぐ」は、スマートフォンで撮影した雲の写真アップロードすることで、写真に写っている雲の種類と状態を知ることができるものである。「くもろぐ」内部では、雲の種類や状態を判別する機械学習の分類器が機能している。その分類器のモデルを構築するために、あらかじめ収集された雲画像に対して、気象の専門家がラベル付けを行うことでデータセットが作成されている。

機械学習問題として、雲画像の分類問題が持つ特徴は、雲の種類や雲の状態を判別することが専門家によってしか行うことができないということである。すなわち、ラベル付きデータを大量に用意することが困難であるということである。一方、雲画像そのものは、空を撮影することで、容易に大量に取得する

ことが可能である。そこで、本研究では、ラベルがつけられていない空の画像もうまく利用して、分類モデルの構築を行う手法を提案する。提案手法では、まず、ラベルがつけられている雲画像を用いて分類モデルを構築する。その後、ラベルがつけられていない雲画像の分類を行い、そのうち、確信度高く分類できた画像を選択する。もともとラベルがつけられている雲画像と選択された画像を用いて、新たに分類モデルを構築するというを行う。

2 関連研究

近年、画像認識においては畳み込みニューラルネットワークを使った手法の実績が顕著である。ResNet と呼ばれる手法では2層を学習するごとに出力と2層前の入力を足し合わせる手法を取り入れることによって多層化を行っても良い結果を得ることができるになっている [1]。何も工夫をせずに多層化を行った際には、層を進んでいけばいくほど出力値が極端になっていく現象が生じるその結果、勾配効果方が意味をなさなくなってしまう学習が進まなくなる問題が生じる。この問題は勾配消失問題と呼ばれるが、ResNet では2層を学習するごとに出力と2層前の入力を足し合わせる手法を取り入れることによって多層化を行っても勾配消失問題が生じなくなり良い結果を得ることができるになっている。精度が劇的に良くなるわけではないが、ResNet を使えば1000層以上の多層化を行ったうえで計算を行うことも可能である。このような素晴らしい層が作られているが、一方でディープラーニングには学習に必要なデータ数が膨大に必要であるという弱点が存在している。特に画像では顕著にたくさんの画像が必要になるこれは画像で使用される畳み込みニューラルネットワーク (CNN) の特性に由来する。CNN はラベル付きの画像を学習することで高い精度を得ることができるが、画像データをスカラー値として入力す

るため、同じ画像でも少しゆがめただけで別のラベルの画像として判別してしまうという弱点が存在する。

この弱点に対応するために Data Augmentation という手法が用いられている [2]。Data Augmentation は画像に回転やズームなどを加えることによって画像の枚数を増やす手法を示している。画像の枚数を増やすことで少しゆがめただけの画像にも対応できるようになる。また、mixup と呼ばれる Data Augmentation の手法を用いている [3]。この手法は二つの画像を混ぜることによって一つの画像を生成し、学習用画像を生成する手法である。混ぜた画像のラベルは二つの画像をどの割合で混ぜたかによって決まる。たとえば、A の画像と B の画像を 0.2 と 0.8 の割合で混ぜた場合、ラベルも A の画像のラベルも 0.2 の割合とし、B の画像のラベルも 0.8 とすることで学習させる。このように盛んにディープラーニング手法の研究や環境の整備が行われたことにより様々な分野からディープラーニングの応用が注目されている [4-6]。

Inception という深層学習モデルも存在している [7]。Inception が登場する前は、最も人気のある CNN は、単により多くの畳み込み層を積み重ねて、ネットワークをより深くし、パフォーマンスの向上を望んでいた。その目的は、優れたローカルトポロジを持つネットワークを設計することである。つまり、入力画像に対して複数の畳み込み操作またはプーリング操作を並列に実行する。すべての出力結果を非常に深い機能マップにステッチする。1×1, 3×3, または 5×5 などのさまざまな畳み込み演算とプーリング演算により入力画像の異なる情報を取得できるため、これらの演算を並列処理し、すべての結果を組み合わせることで画像表現が向上する。一方、Inception ネットワークは複雑である。速度と精度の両方を含む多くのトリックを使用してパフォーマンスを改善する。InceptionV3 では 2 次元畳み込みを 2 つの小さな畳み込みに分割する [8]。たとえば、7×7 畳み込みを 1×7 畳み込みと 7×1 畳み込みに分解する。これには、パラメーターの量を減らすというメリットがある。この非対称畳み込み分割により、効果は対称分割をいくつかの同一の畳み込みに分割するよりも優れており、より多くのより豊かな空間的特徴を処理できることが分かる。

雲の分類を行う研究も行われている。Shi らは数種類の空の曇り度合いの分類や一部の雲形の判別を CNN を用いて判別を行っている [9]。Ye らは 9 種類の雲形と CNN + SVM を用いて雲の種類の判別を行っている [10]。Huertas-Tato らは独自で集めた 8 種類の雲形と random forests を用いて雲の種類の判別を試みた [11]。

3 問題定義

3.1 雲の種類

世界気象機関 (WMO) の分類によれば、雲は 10 種類に分類される。その 10 種類とは、表 1 に示すように、巻雲、巻積雲、巻層雲、高積雲、高層雲、乱層雲、層積雲、層雲、積乱雲、積雲である。雲の高さに応じて、上層、中層、下層の 3 つのグループに分けることができる。上層雲 (図 1) には巻雲、巻積

表 1 雲の種類とデータにおける写真枚数

雲層	雲形	図	枚数
上層雲	巻雲	図 1(a)	1579
	巻積雲	図 1(b)	507
	巻層雲	図 1(c)	379
中層雲	高積雲	図 2(a)	4222
	高層雲	図 2(b)	607
	乱層雲	図 2(c)	37
下層雲	層積雲	図 3(a)	210
	層雲	図 3(b)	65
	積乱雲	図 3(c)	66
	積雲	図 3(d)	4808
空ではない		図 5	372
雲がない空		図 6	78



図 1 上層雲の雲形



図 2 中層雲の雲形

雲、巻層雲が属し、中層雲 (図 2) には高積雲、高層雲、乱層雲が属し、下層雲 (図 3) には層積雲、層雲、積乱雲、積雲が属する。

3.2 雲の状態

雲の種類に加えて、雲の状態というものが定義されている。



図3 下層雲の雲形




図4 雲の状態



図5 空ではない




図6 雲がない空

図7 複数の雲を含む

世界気象機関によって、それぞれの層で10種類ずつ定義されている。雲の状態は、それぞれの層で0から9までの数値で表現される。たとえば、図4(a)は下層雲の状態「1」を示している。これは、「発達していないへんぺいな積雲のある状態」というものである。図4(b)は中層雲の状態「4」を示している。これは、「レンズ型をした高積雲が散在して存在している状態」というものである。

3.3 データと問題の構造

本研究で用いる画像データは、「くもろぐ」アプリを使用す

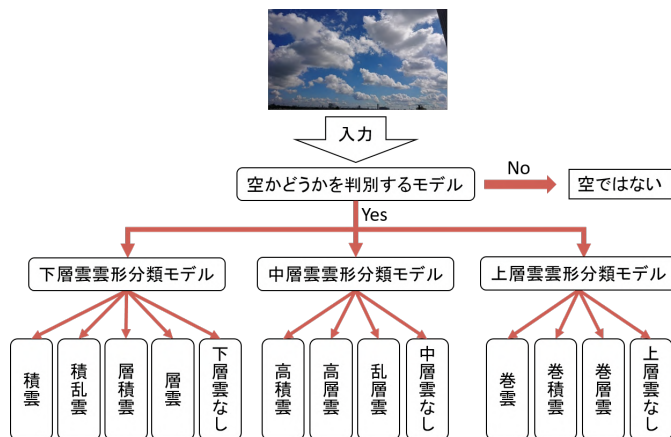


図8 提案手法の全体構造

るユーザがアップロードしたものである。その中で、本研究で利用したラベル付き画像の枚数を表1に掲載する。これらのラベルは、気象の専門家によって付与されたものである。全部で10,025枚ラベル付き写真と42,517枚ラベルなし写真が存在する。

図5や図6のように雲が写っていない画像も存在している。図5のような空を撮影したものではない画像を「空ではない」画像と呼ぶこととする。ラベル付き画像の中には、空ではない画像は372枚存在していた。画像の中には、雲が写っていない画像もある。図6は、雲が写っていない画像の一例である。下層、中層、上層のそれぞれにおいて、雲が存在するという場合もありうる。図7は、下層で積雲、中層で高積雲、上層で巻雲がそれぞれ存在する画像である。

本研究では、ラベル付きデータを、訓練データ、検証データ、テストデータに分割した。比率は、8:1:1とした。訓練データは、機械学習の分類モデルの構築に使用する。検証データは、訓練の途中において、過学習が起こっているかどうかといったことを監視するために使用する。テストデータは、学習されたモデルを評価するために使用する。

まず、提案手法の全体構造(図8)を説明する。入力1枚の画像である。入力された画像は、はじめに、空かどうかを判別するモデルに入力する。もし、空でないと判断されたら、処理はそこで終了する。空であると判断されたら、次に、入力画像を雲の雲形と状態の分類モデルに入力する。下層、中層、上層のそれぞれで分類モデルが構築されており、雲形の場合は、下層雲雲形分類モデル、中層雲雲形分類モデル、上層雲雲形分類モデルという3つのモデルに入力し、それぞれの層でどのような雲が存在するのか、もしくは存在しないのかといったことを知る。

ここでは、空画像の判別問題と、雲の種類と状態の分類問題という2つの問題に取り組むこととなる。

3.4 空画像の判別問題

空画像の判別問題とは、入力された画像が、空の画像であるか、空の画像でないかを判別するという問題である。入力1枚の画像であり、出力は空の画像である場合は1、空の画像で

ない場合は 0 とする。

3.5 雲の種類と状態の分類問題

雲の種類と状態の分類問題とは、入力された画像に、どのような雲が存在しているかを判別する別個の 6 つの問題である。入力共通しており、1 枚の空画像である。6 つの問題とは、以下の通りである。

- 上層雲の雲の種類分類問題
- 中層雲の雲の種類分類問題
- 下層雲の雲の種類分類問題
- 上層雲の雲の状態分類問題
- 中層雲の雲の状態分類問題
- 下層雲の雲の状態分類問題

雲の種類分類は、上層雲、中層雲、下層雲のそれぞれで行う。すなわち、下層雲の分類モデル、中層雲の分類モデル、上層雲の分類モデルを構築し、それぞれで画像に写っている雲の種類判別を行う。たとえば、下層雲には 4 種類の雲がある。下層雲には雲が写っていない「下層雲がない」という場合もある。そのため、下層雲の分類モデルは、5 クラス分類モデルを構築することとなる。中層雲や上層雲にはそれぞれ 3 種類の雲がある。そのため、「中層雲がない」や「上層雲がない」という場合も含めて、それぞれ 4 クラス分類モデルを構築することとなる。たとえば、雲のない画像が入力として与えられた時は、これら 3 つのモデルからは、「下層雲がない」「中層雲がない」「上層雲がない」という出力が得られることが理想となる。

雲の状態分類も、上層雲、中層雲、下層雲のそれぞれで行う。こちらは、それぞれ 10 クラス分類問題となる。

4 空画像の判別

本節は与えられた画像が空画像かどうかを判別するモデルの構築について説明する。

4.1 モデルの構築

図 9 は、画像を入力して、特徴量を抽出し、空画像かどうかを分類する手法の概要を表している。以下の 4 つのステップからなる。

- 画像の読み込み
- Data Augmentation
- 既存モデルによる画像の特徴化
- 分類

まず、このモデルは、入力として画像を 1 枚読み込む。画像の特徴抽出には訓練済みのモデルを使用する。そのため、画像データは 4 次元のテンソルの形状となっている必要がある。訓練済みのモデルに合わせて、テンソルの形は $1 \times 224 \times 224 \times 3$ としている。

次に、画像を様々な方法で変形を行う。このような操作は、Data Augmentation と呼ばれる手法である。Data Augmentation は、深層学習において訓練時に用いるデータを変形させてデータ量を増やす手法である。過学習を避けることができ、モデルの汎用性が向上するとされ、広く一般に利用されている。

本研究では、Keras に付属しているデータ拡張機能を使用した。変形の方法としては、回転、トリミング、色差の変更、歪め、サイズ変更、ノイズ付与など、以下のような変形を行った。

- 画像を $-40 \sim 40$ 度の間でランダムに回転
- 水平・垂直方向に 20% 以内の範囲で平行移動
- $0 \sim 0.2\pi$ で反時計回りシアー変換
- 画像中心に対して 20% 以内の範囲でズーム変形
- 水平方向で反転

深層学習モデルにおいて、画像特徴として現在広く用いられている訓練済みのモデルには、ResNet や InceptionV3 があげられる。本研究では、ResNet50 と InceptionV3 の利用を検討し、事前の実験の結果、InceptionV3 を利用することとした。画像特徴の抽出のために InceptionV3 の畳み込み層の最後の pooling 層を使用する。

InceptionV3 の最後の pooling 層で、画像特徴を抽出した後、さらに 3 つの層を加える。第 1 層は flatten 層である。pooling 層によって出力される特徴ベクトルを平坦化する。第 2、第 3 層は全結合層である。第 2 層のユニット数は 64 と設定した。活性化関数は ReLU を使用する。空かどうかを判別するモデルの出力は空の画像か、空の画像ではないかであるので、第 3 層のユニット数は 1 を設定し、活性化関数はシグモイドを使用した。

このようにして構成された深層学習モデルによって、入力された画像が空の画像かそうでないかを判別することが可能となる。

4.2 モデルの学習

モデルの訓練のために、データを空の画像と、空ではない画像の 2 つ種類に分ける。その結果、空の画像は 9,653 枚、空ではない画像は 372 枚得られた。それらを用いて空かどうかを判断するモデルを構築する。空の画像と空ではない画像の枚数には偏りがある。このようなバランスが取れていないデータを用いて学習を行い、分類器を作成すると、より多くのデータが存在するカテゴリに分類されやすい分類器となる。空の画像と、空ではない画像を分類するとすると、空の画像の方が圧倒的に多いため、分類器は空ではない画像でも、空の画像と分類するようにモデルの正解率が低下することが多い。そのため、データ量のバランスを取る必要がある。本研究では、写真の数に応じて各カテゴリの重みを調整することで、このような正解率の低下を避けるようにしている。

モデルの学習時には Early Stopping を使用して、適切なところで学習を終了させるようにした。すなわち、検証データの正解率を観測し、もし正解率が 10 回連続で更新されなかった時には学習を停止させるようにした。モデルは検証データの正解率は一番高い時点のモデルを保存しておき、分類に利用する。学習率は 1×10^{-5} と設定した。

4.3 実験

訓練データを用いて構築したモデルに対して、テストデータを適用して予測を行った。その結果、テストデータの分類の正解率は 97.10% であった。テストデータに含まれる 40 枚の空で

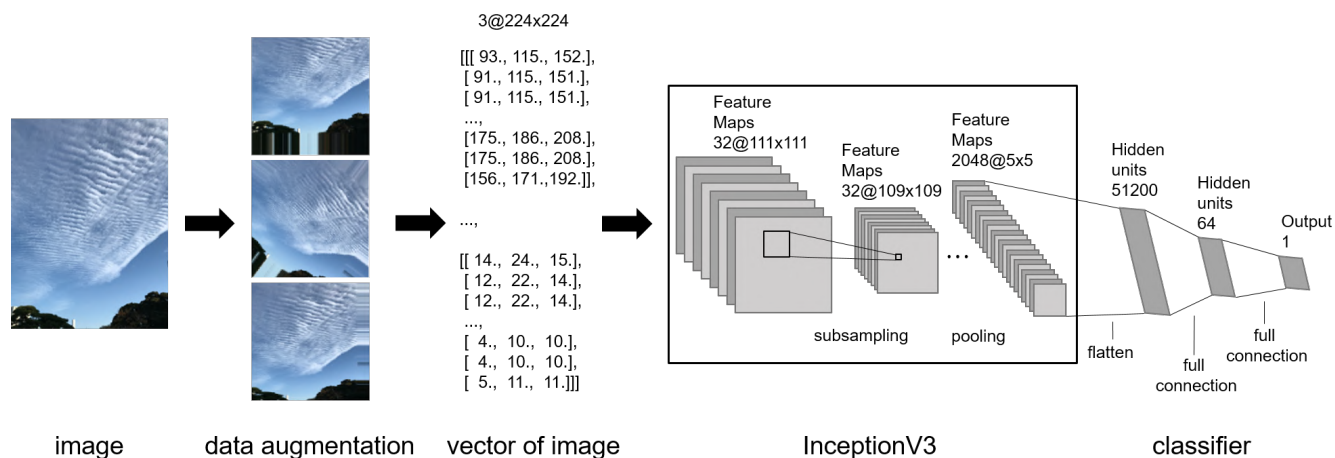


図 9 空かどうかを判別するモデル

表 2 空かどうか判断するの適合率, 再現率, f 値

	適合率	再現率	f 値
空ではない画像	0.72	0.45	0.55
空の画像	0.98	0.99	0.99

妥当であると考えられる。

訓練した空かどうかを判別するモデルを使用して, ラベルなし画像データの予測を行った. その結果, ラベルなし画像データの全 42,517 枚のうち, 41,473 枚の画像が空画像であると予測された.

5 雲の種類の分類

5.1 提案アプローチ

本節では提案アプローチを紹介する. ここでは下層雲の雲の種類を分類する場合について説明する. 中層や上層においても下層と同様に行う. 全体構造は図 11 になっている. まず, 図の中央にはラベル付き画像がある. これらのラベル付き画像を用いて, 下層雲の雲の種類を分類するモデルの学習を行う. ここで訓練されたモデルを初期モデルと呼ぶこととする. 次に, 空かどうかを判別するモデルでラベルなし画像から空の画像のみを取得する. そして, 初期モデルを用いてそれらのラベルなし空画像の分類を行う. 分類結果によって, ラベルなし空画像には予測ラベルがつけられることとなる. 予測ラベルがつけられたラベルなし空画像を, 以後, 疑似ラベル付き画像と呼ぶ. 疑似ラベル付き画像の全体集合から何枚かを選択し, それらと, 初期モデルの訓練で利用したラベル付き画像を合わせて, それら全てを利用して新たにモデルを訓練する.

5.2 初期モデルの構築

初期モデルの構築方法について説明する. これは, 空かどうかを判別するモデルの構造の最後の層以外は全く同じように構築する. 下層には 4 つ種類の雲, すなわち, 層積雲, 層雲, 積雲, 積乱雲が存在する. また, 下層雲が存在しない場合, すなわち, 下層雲なしという場合がある. よって, このモデルは 5 クラス分類を行うモデルとなる. そこで, 最後の層のユニット




図 10 空の画像であると誤って予測された空ではない画像

はな画像のうち, 18 枚が正しく予測され, 22 枚は空の画像であると誤って予測された. また, テストデータに含まれる空の画像の 963 枚のうち, 956 枚は正しく予測され, 7 枚は誤って空の画像ではないと予測された. 今後, データのクリーニングなどが必要であると考えられる. 表 2 は, モデルの適合率, 再現率と f 値を示している. 空ではない画像における適合率, 再現率と f 値がともに比較的低いことが分かる. 図 10 に, 空であると誤って予測された空ではない画像の例をいくつか示す. ここに示すように, これらの写真の一部は実際には空の画像であると考えられるものも存在していた. また, 空の画像の領域が小さいために, 人が空ではない画像と判断したものも存在していた. また, 空が映っており, 雲も写っているが, 人手で雲の種類のラベリングを行った際に雲の種類が判別できなかった画像が含まれていた.

空の画像の判別についての適合率, 再現率, f 値は比較的高いといえる. そのため, ある写真が空を撮影したものであるかどうかを判断するためにこのモデルを使用することはある程度

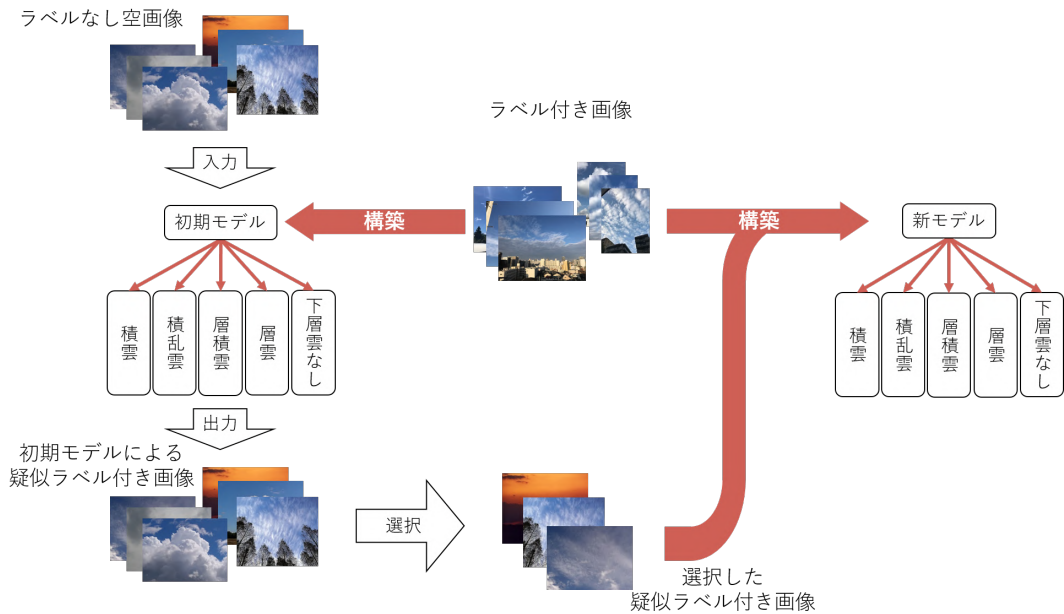


図 11 半教師あり学習の構造

表 3 初期モデル構築に用いる画像数

雲層	ラベル	訓練データ	検証データ	テストデータ
上層雲	巻雲	1271	154	154
	巻積雲	433	37	37
	巻層雲	299	40	40
	上層雲なし	5718	735	735
中層雲	高積雲	3396	413	413
	高層雲	457	66	66
	乱層雲	25	6	6
	中層雲なし	3843	481	481
下層雲	層積雲	180	15	15
	層雲	55	5	5
	積乱雲	50	8	8
	積雲	3812	498	498
	下層雲なし	3624	440	440

数は 5 と設定する．その活性化関数には Softmax を使用する．中層雲（高積雲，高層雲，乱層雲，中層雲なし）と上層雲（巻雲，巻積雲，巻層雲，上層雲なし）では，4 クラス分類となる．

訓練においては，Early Stopping を使用する．学習率は 1×10^{-5} と設定した．各初期モデルを使用するデータは表 3 に示すとおりである．

5.3 半教師あり学習によるモデル構築

初期モデルを利用して得られた疑似ラベル付き画像から，どのように追加で利用する画像を選択するかを説明する．図 12 の左側では，あるラベル（たとえば層積雲）と推定された画像の集合がある．それらには，予測結果の確信度が付与されている．それらを基にしてランキングを行う．そして，確信度が高い順に，半教師あり学習で利用する画像を選択する．

どのラベルの画像を何枚選択するかという手法には，様々な方法が考えられる．ここでは，5 つの手法，すなわち，50%追加モデル，100%追加モデル，100 枚ずつ追加モデル，200 枚ずつ追加モデル，300 枚ずつ追加モデルを検討した．

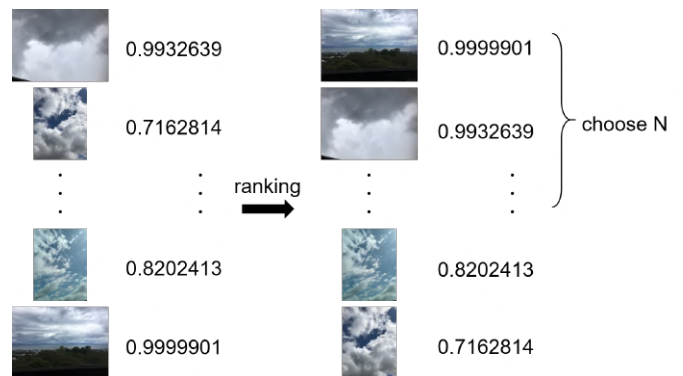


図 12 疑似ラベルの選択方法

50%追加モデルでは，初期モデルでの訓練データの半分の量を追加する．100%追加モデルでは，初期モデルの訓練データと同数の量を追加する．100 枚ずつ追加モデル，200 枚ずつ追加モデル，300 枚ずつ追加モデルでは，各種類の疑似ラベル付き画像を，それぞれ，100 枚，200 枚，300 枚ずつ追加する．

訓練時の検証データと，評価のためのテストデータは，初期モデルでも半教師あり学習によるモデルでも同じものを利用する．疑似ラベル付き画像を追加した訓練データを使用して，分類モデルの学習を行う．

5.4 評価実験

下層雲の分類の初期モデルのデータは表 3 の下層雲部分のデータを使用する．訓練データを用いて，初期モデルの学習を行う．図 13 は，初期モデルの学習データと検証データの損失値と正解率を示している．Early Stopping によって，エポック数が 40 回の時のモデルが用いられることとなった．

テストデータを使用して初期モデルの評価を行った．下層雲雲形モデルの初期モデルの正解率は 77.12%であった．






図 13 学習データと検証データの損失値と正解率



(a) 初期モデル



(b) 200 枚ずつ追加モデル

図 14 混同行列

次に、半教師あり学習によるモデルの訓練を行った。空と判断されたラベルなし画像は 41,473 枚存在した。初期モデルにおいて使用したラベル付き画像の枚数と、半教師あり学習によるモデルを追加の疑似ラベル付き画像の枚数は表 4 に示す。

これらの追加データを用いて、半教師あり学習によるモデルの構築を行った。それらのモデルの訓練時の検証データは、初期モデルの際のものと同じものを使用した。そして、テストデータについても、初期モデルの評価の際のものと同じものを使用した。各モデルを評価結果を表 5 を示す。

下層雲の分類においては、200 枚ずつ追加モデルの正解率が最も高くなった。図 14 は初期モデルと 200 枚ずつ追加モデルの混同行列を示している。混同行列を見てみると、積乱雲と正確に予測された枚数に変化はなかった。一方、下層雲なしと正確に予測できた枚数は増えた。積雲と正確に予測できた枚数は少し減少した一方で、層積雲と正しく予測できた枚数は増えた。全体として、モデルの分類正解率は向上した。

表 5 中において、各層において作成したモデルのうち、最も高い正解率となった結果を太字で表している。結果全体を見たところ、半教師あり学習を用いることによって、分類の正解率が上がったといえる。

本研究では、雲の状態の分類も雲形モデルと同様の手法で行った。表 6 中において、各層において作成したモデルのうち、最も高い正解率となった結果を太字で表している。状態分類においては、半教師あり学習によって正解率は大幅には向上しないということが分かった。50%追加モデルのように、元のデータ量に応じてデータを追加する方が正解率の向上が見込めると考えられる結果となった。

6 まとめと今後の課題

本研究では、疑似ラベル付き半教師付き学習によって、雲の種類と状態を分類する手法を提案した。ラベルなしデータを効果的に使用してモデルを構築することで、より高い正解率を得ることができることが示された。

今後の課題としては、まず、今回、疑似ラベル付き画像の使用枚数について、5つの方法を試したが、今後はより多くの方法を試すことで、より良いデータ追加の方法を模索する予定である。また、今回、最終的なモデル構築に利用できたのは、疑似ラベル付き画像のうち、確信度が高いものだけであった。しかし、初期モデルによる分類の確信度が低い画像も活用したモデル構築の手法を検討したいと考えている。

謝 辞

本研究の一部は JSPS 科学研究費助成事業 JP16H02906, JP17H00762, JP18H03244, JP18H03243 による助成を受けたものです。ここに記して謝意を表します。

文 献

- [1] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pp. 770–778, 2016.
- [2] Alex Krizhevsky, Ilya Sutskever, and Geoffrey E Hinton. Imagenet classification with deep convolutional neural networks. In *Advances in neural information processing systems*, pp. 1097–1105, 2012.
- [3] Hongyi Zhang, Moustapha Cisse, Yann N Dauphin, and David Lopez-Paz. mixup: Beyond empirical risk minimization. *arXiv preprint arXiv:1710.09412*, 2017.
- [4] Guohua Shen, Tomoyasu Horikawa, Kei Majima, and Yukiyasu Kamitani. Deep image reconstruction from human brain activity. In *Processing of the Proceedings of the International Joint Conference on Neural Networks*, pp. 1049–1056, 2017.
- [5] Angjoo Kanazawa, Shubham Tulsiani, Alexei A. Efros, and Jitendra Malik. Learning category-specific mesh reconstruction from image collections. In *Proceedings of the European Conference on Computer Vision*, pp. 386–402, 2018.
- [6] Dong Huk Park, Lisa Anne Hendricks, Zeynep Akata, Anna Rohrbach, Bernt Schiele, Trevor Darrell, and Marcus Rohrbach. Multimodal explanations: Justifying decisions and pointing to the evidence. In *Proceedings of the IEEE*

表 4 追加データ枚数

		初期モデル	50%追加モデル	100%追加モデル	100 枚ずつ追加モデル	200 枚ずつ追加モデル	300 枚ずつ追加モデル
雲層	種類	訓練データ	追加データ	追加データ	追加データ	追加データ	追加データ
上層雲	巻雲	1271	635	1271	100	200	300
	巻積雲	433	216	433	100	200	300
	巻層雲	299	149	299	100	200	300
	上層雲なし	5718	2859	5718	100	200	300
中層雲	高積雲	3396	1698	3396	100	200	300
	高層雲	457	228	457	100	200	300
	乱層雲	25	12	25	100	200	300
	中層雲なし	3843	1921	3943	100	200	300
下層雲	層積雲	180	90	180	100	200	300
	層雲	55	27	55	100	200	300
	積雲	3812	1906	3812	100	200	300
	積乱雲	50	25	50	100	200	300
	下層雲なし	3624	1812	3624	100	200	300

表 5 雲形分類モデルの実験結果

雲層	モデル	正解率
上層雲	初期モデル	80.33%
	50%追加モデル	81.26%
	100%追加モデル	79.91%
	100 枚ずつ追加モデル	81.36%
	200 枚ずつ追加モデル	82.50%
	300 枚ずつ追加モデル	80.53%
中層雲	初期モデル	71.32%
	50%追加モデル	70.08%
	100%追加モデル	72.04%
	100 枚ずつ追加モデル	69.97%
	200 枚ずつ追加モデル	69.87%
	300 枚ずつ追加モデル	69.46%
下層雲	初期モデル	77.12%
	50%追加モデル	78.57%
	100%追加モデル	77.12%
	100 枚ずつ追加モデル	78.26%
	200 枚ずつ追加モデル	79.71%
	300 枚ずつ追加モデル	77.63%

表 6 状態分類モデルの実験結果

雲層	モデル	正解率
上層雲	初期モデル	74.12%
	50%追加モデル	74.12%
	100%追加モデル	70.60%
	100 枚ずつ追加モデル	69.46%
	200 枚ずつ追加モデル	67.39%
	300 枚ずつ追加モデル	68.11%
中層雲	初期モデル	60.55%
	50%追加モデル	57.03%
	100%追加モデル	54.14%
	100 枚ずつ追加モデル	49.89%
	200 枚ずつ追加モデル	49.58%
	300 枚ずつ追加モデル	51.75%
下層雲	初期モデル	64.18%
	50%追加モデル	65.63%
	100%追加モデル	64.18%
	100 枚ずつ追加モデル	48.96%
	200 枚ずつ追加モデル	48.96%
	300 枚ずつ追加モデル	50.20%

Conference on Computer Vision and Pattern Recognition, pp. 8779–8788, 2018.

- [7] Christian Szegedy, Wei Liu, Yangqing Jia, Pierre Sermanet, Scott E. Reed, Dragomir Anguelov, Dumitru Erhan, Vincent Vanhoucke, and Andrew Rabinovich. Going deeper with convolutions. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pp. 1–9, 2015.
- [8] Christian Szegedy, Vincent Vanhoucke, Sergey Ioffe, Jonathon Shlens, and Zbigniew Wojna. Rethinking the inception architecture for computer vision. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pp. 2818–2826, 2016.
- [9] Cunzha Shi, Chunheng Wang, Yu Wang, and Baihua Xiao. Deep convolutional activations-based features for ground-based cloud classification. *IEEE Geoscience and Remote Sensing Letters*, pp. 816–820, 2017.
- [10] Liang Ye, Zhiguo Cao, and Yang Xiao. Deepcloud: Ground-based cloud image categorization using deep convolutional features. *IEEE Transactions on Geoscience and Remote*

Sensing, pp. 5729–5740, 2017.

- [11] Javier Huertas-Tato, FJ Rodríguez-Benítez, Clara Arbizu-Barrena, Ricardo Aler-Mur, Ines Galvan-Leon, and David Pozo-Vázquez. Automatic cloud-type classification based on the combined use of a sky camera and a ceilometer. *Journal of Geophysical Research: Atmospheres*, pp. 11–045, 2017.