

AI システムの産業適用に関する一考察

渡辺 聡 宮永 瑞紀

株式会社日立製作所 研究開発グループ デジタルテクノロジーイノベーションセンタ

〒185-8601 東京都国分寺市東恋ヶ窪 1-280

E-mail: {satoru.watanabe.aw, mizuki.miyana.fc}@hitachi.com

あらまし AI (Artificial Intelligence) システムの産業適用における最大の課題の一つは、効果検証 (PoC : Proof of Concept) の実施に長期間を要する点である。PoC の実施には半年から 1 年を要し、AI システムの産業適用における障壁となっている。また、PoC の結果、AI システムが実用化に至らないケースが発生し、これにより生じる工数の無駄が、大きなリスク要因になっている。本稿では、これらの原因として、(i) 業務知識と AI 技術の融合が必要な点、(ii) データの特徴量を決定するために AI システムの動作が必要な点、の 2 点を抽出した。また、これらの原因分析をもとに、AI システムの適用効果見積もりツール (Xsolver) を提案した。Xsolver は、学習データの不足、および、特徴量設計の不備を指摘する機能を有し、AI システムの検証を PoC の初期の段階で行うことにより PoC の短期間化を実現する。

キーワード AI システム、産業適用、Proof of Concept、効果検証、AI 適用効果見積もり

1. はじめに

第三次 AI ブームにより、AI システムの産業適用が拡大している。本ブームにおいては、従来、人間が有していた業務知識を、ビッグデータを用いて機械に習得させることで、人間が行っていた業務を AI で代替することが期待されている[1,4]。しかしながら、産業適用においては、法規制やコンプライアンスなど、データに含まれない業務知識が存在する。データに含まれない業務知識の利用は、AI システムの実用化に必要不可欠である[9, 10]。

データに含まれない業務知識に関しては形式知化して、機械に入力する必要がある。そのため、AI システムの産業適用においては、業務知識は以下の二つに分類される。

- (1) 形式知化して機械に入力する業務知識
- (2) データから習得する業務知識

産業分野に適用される AI システムでは、図 1 に示すように、(1)の業務知識により解空間を限定し、限定された解空間に対して、(2)の業務知識と AI 技術を用いた探索が行われる。

AI 技術が最適解を発見できるか否かは、問題の難しさ、使用する AI のアルゴリズム、学習データの質と量など、多様な要因により変動する。そのため、AI システムの導入前には、AI システムの実用化の可否を判定するための効果検証 (PoC : Proof of Concept) が実施される[3]。

AI システムの PoC において、我々が経験したスケジュール例を図 2 に示す。図 2 に示すように、AI システムの PoC においては、目標設定、業務理解・データ準備、プログラム開発、精度向上の工程を経て、AI システムの効果が検証される。PoC の完了には半年から




図 1 (1)形式知で制限する探索空間の領域と、(2)業務知識を学習した AI 技術で探索する領域の模式図




図 2 AI システムの PoC のタイムスケジュール例

1 年の期間を要する。また、PoC の結果、AI システムが実用化に至らないケースが発生し、これにより生じる工数の無駄が、AI システムの産業適用における大きなリスク要因になっている[5]。

AI システム以外のシステム開発においては、リスクを最小限に抑える工夫が行われている。データベースシステムを例にとれば、机上見積もり、テスト機検証、実機検証などの各工程において、性能、信頼性、保守性などの各種観点からシステムの実用性が検証される。

AI システムにおいては、段階的に実用性を検証する施策が不足しているといえる。特に、図 2 のプログラム開発を実施し、AI システムを試動しないと実用化の

判定ができない点が大きなリスク要因になっている。

本研究では、これらの原因として、(i) 業務知識と AI 技術の融合が必要な点、(ii) データの特徴量を決定するために AI システムの動作が必要な点、の 2 点を抽出した。また、(i)(ii)の要因分析をもとに、PoC 初期の段階での効果見積り目的として、AI システムの適用効果見積りツール (Xsolver) を提案した。Xsolver は、学習データの不足、および、特徴量設計の不備を、PoC の初期の段階で指摘する機能を有し、AI システムの PoC の短期間化を可能にする。本稿の貢献は以下の 2 点である。

- ・ 複数の PoC に関与した経験から、AI システムの産業適用におけるリスク要因として、(i)(ii)の二つの要因を抽出した点
- ・ (i)(ii)の要因分析をもとに PoC の短期間を目的として、AI システムの適用効果見積りツール (Xsolver) を提案した点

2. AI システムの産業適用における課題

本章では、AI システムの産業適用の課題、特に、PoC でのプログラム開発工数が増大する原因について論じる。

2.1 業務知識と AI 技術の融合

第 1 章において、業務知識が(1)形式化して機械に業務知識と、(2)データから習得する業務知識に分類されることを説明した。(1)と(2)は、その特性の違いから、図 3 に示すように、(1-1)(1-2)および(2-1)に細分化される。

(1-1) 必須業務知識

(1-2) 蓋然性の高い業務知識

(2-1) 蓋然性の低い業務知識

業務知識の例を表 1 に示す。表 1 に示すように(1-1)必須業務知識とは、設備の制約や工場の決まり事など、遵守が必要不可欠な知識である。これらの業務知識から逸脱した結果は実行不可能であり、必須業務知識から逸脱した学習データは存在しない。そのため、(1-1)の業務知識は形式化して機械にされる。

(1-2)と(2-1)の違いは、蓋然性の程度の差であり、明確な区分は存在しない。学習データが十分にあり、AI 技術が高い精度を有すれば(1-2)に区分する知識は少なく、(2-1)に区分する知識が多くなる。一方、AI 技術の精度が低い場合は、多くの知識を(1-2)に区分する必要がある。

図 4 に示すように、(1-2)と(2-1)の区分は、AI システムの開発コストと解の特性に影響を及ぼす。(1-2)に区分する知識が多いほど、プログラム開発の工程が増大し、AI システムの開発コストが増大する。また、(1-2)に区分する知識が多いほど安定した解が得られる。

(1)形式化して機械に業務知識 (2) データから習得する業務知識




図 3 業務知識の詳細分類

(1-2)に区分する知識が多い

(2-1)に区分する知識が多い




図 4 (1-2)と(2-1)の知識の区分が AI システム

の開発コストと解の特性に与える影響の模式図

一方、(2-1)に区分する知識が少ないと、AI システムが発見的な解を得る可能性は減少する。

現状、(1-2)と(2-1)の業務知識の区分は、データ分析担当者の属人的なノウハウにもとづいて決定されている。(1-2)と(2-1)の区分の見直しは、図 2 の精度向上の工程で実施されており、PoC の手戻りが発生する一因になっている。

2.2 動的特徴量

AI システムの産業適用における二つ目の課題は、先行する判断結果にもとづき変化する動的特徴量の存在である。動的特徴量の例としては、以下が挙げられる。

- ・ 商品の在庫量
- ・ 原材料の在庫量
- ・ 稼働可能な人員数

例えば、商品の在庫量は、前日に生産した商品量によって変動し、この値が決定しないと、商品の過不足は判断できない。

動的な特徴量は AI システムに固有の問題ではない。しかしながら、近年注目されている、Cyber Physical System[9, 10]や Digital Twin[12]では、AI 技術を継続的に活用することで、実社会とサイバーシステムの融合を図っている。Cyber Physical System や Digital Twin においては、動的特徴量の問題に対して、センサから収集される情報をリアルタイムに AI システムに入力し、データを補完する研究が行われている[13, 14]。しかしながら、本手法は、AI システムが、先行の判断結果に基づいて後続の判断を行う場合には適用できない。AI システムの産業適用においては、先行の判断が後続の判断に影響するケースが多く、動的特徴量の発生は回避困難である。

表 1 業務知識の例

(1-1)	必須業務知識	<ul style="list-style-type: none"> ・ライン A で製造可能な商品は商品 X から商品 Z である。 ・ライン A は二つの商品を同時に製造可能である。 ・従業員の休憩時間は 12:00 – 13:00 である。
(1-2)	蓋然性の高い業務知識	<ul style="list-style-type: none"> ・製造商品の変更は最小限にする。 ・複数商品を同時に製造する場合、可能な限り同一の商品を製造する。
(2-1)	蓋然性の低い業務知識	<ul style="list-style-type: none"> ・商品 X の後には商品 Y を製造することが多い。 ・商品 X の後にはなるべく商品 Z を製造しない。

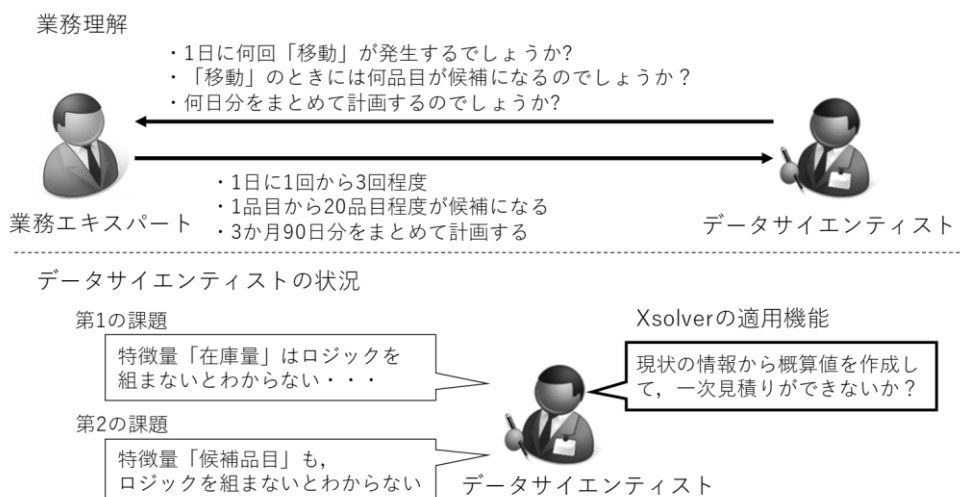


図 5 Xsolver のユースケース

表 2 Xsolver が用いる概算値

	概算値	内容
1	候補選択の合計回数	計画立案において実行する候補選択の回数
2	候補数の概算値	1回の候補選択で候補となるエントリ数の概算値
3	動的特徴量	計画対象データに含まれていない特徴量の概算値

3. Xsolver の提案

本章では、PoC 期間の短縮を目的として、AI システムの適用効果見積もりツール Xsolver を提案する。3.1 節において Xsolver のユースケースを、3.2 節において Xsolver が対象とする AI システムを説明する。また、3.3 節において Xsolver の機能について説明する。

3.1 Xsolver のユースケース

図 5 に Xsolver のユースケースを示す。業務理解の工程において、データサイエンティストは業務エキスパートに対して質疑応答を行う。本工程により、データサイエンティストは業務エキスパートが実施している業務内容の概要を理解する。しかしながら、2.1 節と 2.2 節に説明した課題が存在し、現状では、PoC が完了するまで AI 技術の適用効果は不明である。このようなデータサイエンティストの状況に対し、Xsolver は、業務理解の工程で取得可能な情報から、AI 技術の適用効果を見積もる機能を提供する。

Xsolver が利用する概算値を、表 2 に示す。Xsolver

が使用する概算値の一つ目は、計画立案において実行する候補選択の回数である。例えば、一日当たり平均 3 回の候補選択が行われ、一月分の計画立案を行う場合は、稼働日を 30 日として、 $3 \times 30 = 90$ 回の候補選択が行われると概算できる。

Xsolver が使用する概算値の二つ目は、候補数の概算値である。例えば、人間が計画立案する場合に、何個の候補を勘案しているかを参考にして概算可能である。

Xsolver が使用する概算値の三つ目は、動的特徴量である。2.2 節で説明した「商品の在庫量」や「原材料の在庫量」は先行する判断結果によって変化するため、正確な値を設定するには AI システムを動作させる必要がある。Xsolver は、動的特徴量に概算値を設定し、AI システムを動作させずに、AI システムの適用効果を見積もる機能を提供する。

3.2 Xsolver が対象とする AI システム

数理モデルが対象とする問題の分類に関しては、[2] において、事例を用いて、配置問題、スケジューリン

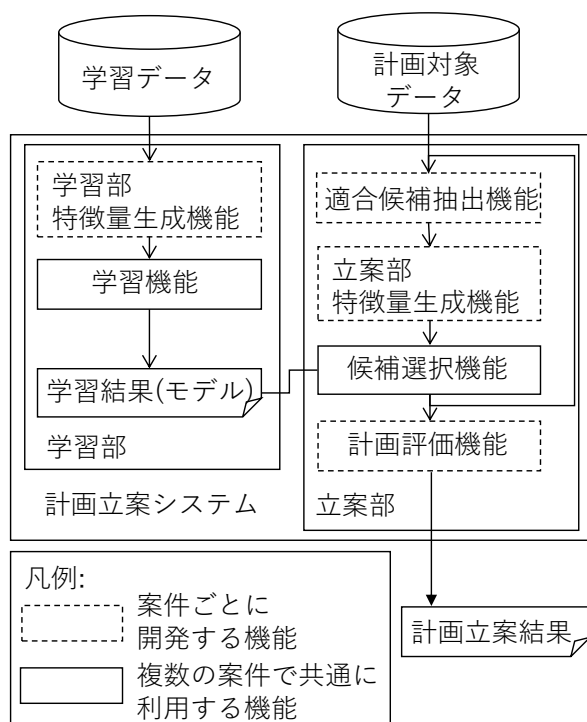


図 6 本稿で想定する AI システムの構成図

グ問題，経路問題などの問題のクラスが提示されている．このうち，Xsolver はスケジューリング問題を対象とする．スケジューリング問題は，工場ラインの製造計画立案や，人員配置など，広い応用事例がある問題クラスである．

本稿で想定する AI システムの構成図を図 6 に示す．図 6 に示すように，想定する AI システムは，学習部と立案部から構成され，学習データと計画対象データを入力として，計画立案結果を出力する．図 6 において，破線で示した機能は案件ごとに開発する機能であり，実線は複数の案件で共通に利用する機能を示している．

学習部は学習データから業務知識を学習し，人間の判断を模倣するための学習結果(モデル)を生成する．学習データと特微量生成機能の例を図 7 に示す．図 7 の例では，学習データとして，商品名，在庫量，予想販売量，製造可能量が記載されている．また，製造可能な商品 A，B，C などの中から，商品 A の製造を選択したことが記載されている．

学習部特微量生成機能は，学習データを入力として，特微量データを生成する．特微量データにおいては，商品名はエンコードされ商品コードになり，在庫量と予想販売量の除算によって，余剰在庫量を計算している．また，製造されたデータに正解フラグとして“1”が記載されている．

立案部は，計画対象データをもとに，計画を立案する．立案部において，適合候補選択，特微量生成，候

学習データ

商品名	在庫量	予想販売量	製造可能量	製造選択
A	10,000	3,000	1,000	✓
B	5,000	500	300	
C	150,000	4,000	2,000	
⋮	⋮	⋮	⋮	⋮

特微量データ

商品コード	余剰在庫日数	製造可能量	正解フラグ
1	3.33	1,000	1
2	10.0	300	0
3	37.5	2,000	0
⋮	⋮	⋮	⋮

図 7 学習データと特微量生成機能の例

特微量データ

商品コード	余剰在庫日数	製造量
1	3.33	1,000
2	10.0	300
3	37.5	2,000
⋮	⋮	⋮

商品コード	選択確率
1	0.53
2	0.20
3	0.05
⋮	⋮

図 8 候補選択機能の入出力例

補選択は複数回実行され，計画評価部において，良好な計画が選定されてシステムから出力される．(1-1)および(2-1)の業務知識は，立案部の適合候補抽出機能に実装され，業務知識から逸脱するデータは計画対象データから除かれる．

図 8 には，立案部の候補選択機能の入出力例を示している．選択候補選択機能は，学習結果(モデル)を用いて，特微量データを入力として，選択結果を出力する．選択結果には，各商品の選択確率が記載されており，この選択確率は，学習データをもとに各商品が製造される確率の予測値である．

3.3 Xsolver の機能

Xsolver のシステム構成図を図 9 に示す．図 9 の Xsolver では，以下の三つの機能が追加されている．

- (I) 適合候補見積もり機能
- (II) 動的特微量見積もり機能

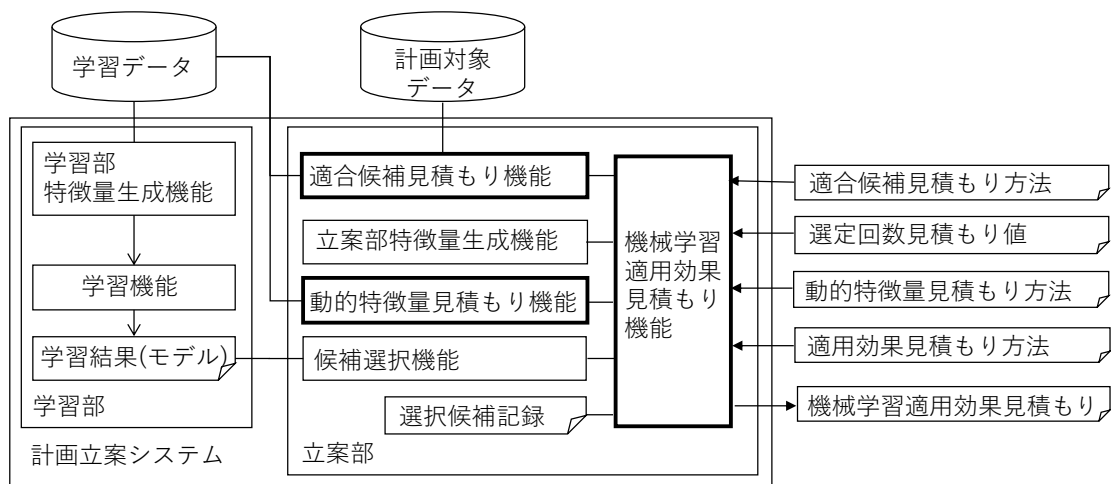


図 9 Xsolver のシステム構成図

商品コード	選択確率
1	0.53
2	0.20
3	0.05
⋮	⋮

①少数の高確率と多数の低確率

商品コード	選択確率
2	0.43
6	0.40
7	0.42
⋮	⋮

②多数の高確率

商品コード	選択確率
3	0.03
8	0.02
9	0.06
⋮	⋮

③多数の低確率

図 10 Xsolver の選択候補記録に格納される選択候補の例

(III) 機械学習適用効果見積もり機能

(I)の適合候補見積もり機能は、図 6 の適合候補選定機能を代替する機能である。計画対象データには、生産可能な商品名（A、B、C など）が記載されており、「適合候補見積もり方法」の入力に従い、適合候補を選択する。

(II)の動的特微量見積もり機能は、学習結果の利用に必要な特微量を「動的特微量見積もり方法」の入力に従って見積もる機能である。動的特微量見積もり方法としては、例えば、「学習データの同一商品の特微量を用いる」といった入力が想定される。本入力をもとに、(II)の動的特微量見積もり機能は、図 6 における、余剰在庫量や製造量などの特微量の見積もりを行う。

(III)の機械学習適用効果見積もり機能は、動的特微量見積もり機能が見積もった特微量を用いて候補選択を行い、その結果を選択候補記録に記録する。また、「選定回数見積もり値」の入力に従って、複数回の候補選択を実施する。(III)の機械学習適用効果見積もり機能が適用効果を見積もる方法に関しては、次節で説明する。

3.4 Xsolver の適用例

Xsolver の機械学習適用効果見積もり機能は、図 10 に示すように、候補選択機能の選択した候補を記録する。候補選択機能の出力は、高確率の選択確率を有する商品コードの個数に応じて、①少数の高確率と多数の低確率のケース、②多数の高確率のケース、③多数の低確率のケースに分けられる。ケース①において、

機械学習は少ない計算量で、熟練者の過去の履歴と同等の解を出力可能と想定される。ケース②においては、機械学習は、解のばらつきはあるものの、熟練者と同等の解を出力可能と想定される。一方、ケース③が発生した場合、すべての選択候補が熟練者に選択されにくい候補であり、AI システムによる熟練者と同等の解の出力は困難である。ケース③が発生する原因としては、学習データの不足、あるいは、特微量の設計不備が考えられる。

機械学習適用効果見積もり機能は、候補選択記録を用いて、AI 技術の適用効果を見積もる。図 11 は、機械学習適用効果見積もり機能の一つ目の出力例である。図 11 は、候補選択記録にケース③が存在する場合の出力であり、学習データの不足、もしくは、特微量の不備の可能性が出力されている。図 12 は、機械学習適用効果見積もり機能の二つ目の出力例である。機械学習適用効果見積もり機能は、各選択候補から選択確率が閾値以上の候補の個数を出力する。また、候補数の乗算により、AI システムの探索空間の広さを見積もる。

従来、図 11 や図 12 の見積もりは、PoC の完了後に取得できる情報である。これに対し、Xsolver を用いることにより、PoC の初期の段階で取得可能になる。図 2 において、プログラム開発の前までの工程に 2 から 5 ヶ月、プログラム開発以降の工程に 2 から 6 ヶ月を要する。Xsolver は、プログラム開発の初期の段階で AI 技術の適用効果を見積もる機能を提供する。

機械学習選択結果のN回目にて高確率のエントリを選択できなかった。学習データの不足の可能性がある。特徴量設計の見直しが必要な可能性がある。 候補選択N回目			
商品コード	余剰在庫量 見積もり値	製造可能量 見積もり値	選択確率
11	4.33	500	0.12
21	5.0	300	0.21
22	7.5	200	0.21
⋮	⋮	⋮	⋮

図 11 Xsolver の出力例 1

機械学習により探索する候補数の見積もり値は10,102です。					
候補選択回数	1	2	3	125
高確率エントリ数	3	5	4	5

図 12 Xsolver の出力例 2

4. 関連研究

機械学習と業務知識の融合は、AI システムの普及に不可欠な技術課題である。金融、保険、薬の処方などの分野では、厳しい規制と高いコンプライアンスが求められ、これらに対応するための業務知識が必要不可欠である[6]。業務知識の形式知化を促進するために、オントロジーを活用した研究[7]や、表現学習 (Representation learning) を用いた研究[8, 16]が行われている。また、近年では、Cyber Physical System (CPS) を実現する手段として、機械学習と業務知識の融合に関心が集まっている[9, 10]。

If-Then 文で表現されるルールを自動的に獲得する仕組みとしては、1980 年代を中心にエキスパートシステムが研究された。しかしながら、ルールの獲得には大きな工数を要し、その利用は医療などの一部の分野にとどまっている[15]。産業分野における人間と機械の共生に関しては、[11]において提言がまとめられている。[11]においては、人間と機械の共生におけるあるべき姿として、Multiverse Mediation のコンセプトが提案され、人-人、人-機械、機械-機械の相互作用から得た知識のデジタル化・共有の重要性が示されている。

以上の状況を鑑みると、本稿で指摘した機械学習と業務知識の融合の課題は、AI 技術の産業適用における主要課題といえる。業務知識の内容は企業ごとに多種多様である。そのため、Xsolver で提案したように、人間系を包含したシステム開発の取り組みが必要不可欠であると考えられる。

5. まとめ

AI (Artificial Intelligence) システムの産業適用における最大の課題の一つは、効果検証 (PoC: Proof of Concept) の実施に長期間を要する点である。PoC の実

施には半年から 1 年を要し、AI システムの産業適用における障壁となっている。また、PoC の結果、AI システムが実用化に至らないケースが発生し、これにより生じる工数の無駄が、大きなリスク要因になっている。本稿では、これらの原因として、(i) 業務知識と AI 技術の融合が必要な点、(ii) データの特徴量を決定するために AI システムの動作が必要な点、の 2 点を抽出した。また、これらの原因分析をもとに、AI システムの適用効果見積もりツール (Xsolver) を提案した。Xsolver は、学習データの不足、および、特徴量設計の不備を指摘する機能を有し、AI システムの検証を PoC の初期の段階で行うことにより PoC の短期間化を実現する。

参 考 文 献

- [1] 北原聖子, “AI 等の技術が労働市場に与える影響に関する内外の研究動向について,” 内閣府経済社会総合研究所, 2018.
- [2] 山下浩, 蒲地政文, 畔上秀幸, 斎藤努, 佐々木規雄, 滝根哲哉, 金森敬文, “モデリングの諸相,” 日本オペレーションズ・リサーチ学会監修, 近代科学社, 2016.
- [3] 田中淳, “デジタル活用を阻む「PoC 貧乏」, 脱出の鍵はアジャイル,” 日経×TECH, 2018.
- [4] Xu, Li Da, and Lian Duan. “Big data for cyber physical systems in industry 4.0: A survey,” Enterprise Information Systems 13.2, 2019.
- [5] 村上万純, “なぜ永遠に PoC を続けるのか? 企業の AI 導入が進まない根深い理由,” ITmedia, 2019.
- [6] Martin, Andreas, et al. “Preface: Combining machine learning with knowledge engineering (AAAI-Make 2019),” CEUR Workshop Proceedings. Vol. 2350. CEUR Workshop Proceedings, 2019.
- [7] Rajbhandari, Sachit, et al. “Leveraging machine learning to extend Ontology-Driven Geographic Object-Based Image Analysis (O-GEOBIA): a case study in forest-type mapping,” Remote Sensing 11.5, 2019.
- [8] De Koninck, Pieter, Seppe vanden Broucke, and Jochen De Weerd. “act2vec, trace2vec, log2vec, and model2vec: Representation Learning for Business Processes,” International Conference on Business Process Management. Springer, Cham, 2018.
- [9] Sanin, Cesar, et al. “Experience based knowledge representation for Internet of Things and Cyber Physical Systems with case studies,” Future Generation Computer Systems 92, 2019.
- [10] Kovalenko, Olga, et al. “AutomationML Ontology: Modeling Cyber-Physical Systems for Industry 4.0,” IOS Press Journal, 2018.
- [11] ロボット革命イニシアティブ協議会, “Revitalizing

Human-Machine Interaction for the advanced society,” 2019.

[12] Tao, Fei, et al. “Digital twin-driven product design, manufacturing and service with big data,” The International Journal of Advanced Manufacturing Technology 94.9-12, 2018.

[13] Palaniswami, Marimuthu, Aravinda S. Rao, and Scott Bainbridge. “Real-time monitoring of the great barrier reef using internet of things with big data analytics,” ITU J.: ICT Discoveries 1.13, 2017.

[14] Fang, Shifeng, et al. “An integrated system for regional environmental monitoring and management based on internet of things,” IEEE Transactions on Industrial Informatics 10.2, 2014.

[15] Oyelade, Olaide Nathaniel, and N. Owamoyo. “A survey of medical diagnostic reasoning algorithms and their applications in medical expert systems,” FUDMA Journal of sciences-ISSN: 2616-1370 2.4, 2018.

[16] Li, Yingming, Ming Yang, and Zhongfei Mark Zhang. “A survey of multi-view representation learning,” IEEE Transactions on Knowledge and Data Engineering, 2018.