

# 音声感情データ解析によるコールセンター従事者の 離職懸念発見手法の提案

玉川 諒† 有次 正義††

† 熊本大学大学院自然科学教育部 〒 860-8555 熊本県熊本市中央区黒髪 2 丁目 39 番 1 号

†† 熊本大学大学院先端科学研究部 〒 860-8555 熊本県熊本市中央区黒髪 2 丁目 39 番 1 号

E-mail: †tamagawa@st.cs.kumamoto-u.ac.jp, ††aritsugi@cs.kumamoto-u.ac.jp

あらまし コールセンター業界全体で、高い離職率というのが大きな問題となっている。それは、コールセンター業務が本質的にストレスフルな仕事で、オペレータは無自覚に不満を溜め込んでしまうことが大きな原因の一つであると考えられる。この課題を解決するために、オペレータの抱える隠れた離職懸念を事前に捉え、適切にケアすることが求められる。そこで、本論文では、音声感情データを解析することによって、離職懸念を抱えるオペレータを特定することを目的とする。具体的には、日々の会話の中から、そのオペレータを特徴付ける会話を抽出し、それを用いてオペレータをクラスタリングすることで、離職懸念者を特定することを目指す。

キーワード コールセンター, 感情分析, 時系列データ, 分類

## 1 はじめに

企業にとってコールセンターは、単なる電話での応答窓口ではなく、顧客と直接の対話ができる数少ない接点であり、経営戦略の拠点として注目されている。新規顧客の獲得や顧客満足度の向上、顧客の維持、マーケティングなど、コールセンターにおける役割は多岐にわたる。そのため、対応品質の向上や、オペレータ数の確保が必要となる [3]。しかし、近年コールセンター業界において、高い離職率というのが大きな問題となっている。オペレータ全体の離職率が 30% 以上のセンターが約 37% を占め、新人オペレータ離職率が 30% 以上のセンターが約 55% を占めるという調べがある [5]。高い離職率は、高いコストをかけて採用・育成したオペレータが辞めることによる経済的な打撃や、ベテランのオペレータが辞めることによる対応満足度の低下など、多くの問題をもたらす。離職の原因として、管理者の目が全てのオペレータに行き届かず、適切なケアが行えないことが考えられるが、そもそもオペレータ自身も無自覚なまま不満を溜め込み爆発させるケースも多い。そこで、オペレータの抱える隠れた離職懸念を事前に捉え、適切なケアをすることが求められる。

本論文では、離職者には離職者特有の会話のパターンが現れるのではないかと仮定し、オペレータをクラスタリングすることで、離職者と在職者に分類しようと考えた。このとき、二値分類ではなく、多クラス分類とした。これは、離職者の中にもタイプがいくつか存在し、同様に在籍者の中にもタイプがいくつか存在するだろう、と考えたためである。提案手法では、まず、日々の会話の中から、そのオペレータを特徴付ける会話を抽出し、それを用いてオペレータをクラスタリングする。その後、離職者の多く含まれるクラスに属する在職者を離職懸念あり、と判断をする。より具体的には、オペレータを

特徴付ける会話を抽出する際に、会話同士の類似度を計算しながらこの処理を行う。このとき、計算手法には Dynamic Time Warping (DTW) [8] を用いる。

本論文は以下のように構成する。第 2 章ではコールセンター分野並びに感情解析に関する研究について述べる。第 3 章では問題定義を行う。第 4 章では提案手法について述べる。第 5 章では実験、第 6 章で本論文のまとめについて述べる。

## 2 関連研究

近年、コールセンター業務に対して、様々な観点から分析が行われている。例えば、テキストマイニングの観点からは、Mishne ら [1] や那須川 [2] が挙げられる。Mishne らは、音声認識により文字起こしを行い、テキストマイニングによって、会話の重要度を特定し、問合せに対する解決策を検索するシステムを提案した。那須川は、会話から、話題の抽出や、問合せの増減傾向などを分析した。他にも、受電量予測の観点からは、伊藤 [3] や田原ら [4] が挙げられる。伊藤は、曜日や季節などの周期性を考慮し、重回帰分析モデルによって受電量の予測をした。田原らは、祝日明けや年度始めといった、特異な要素にも堅牢な時系列解析手法を提案した。これらの研究は、顧客満足度の向上によって企業の利益を増やすことが目的である。これに対し、本論文は、損失を減らすことにフォーカスし、離職を抑制することを目的とした、という違いがある。また、対象とするデータにも違いがあり、本論文は、オペレータの音声感情データを使用した最初の事例となる。

離職の抑制を目的とした事例として、オペレータの属性や勤怠、パフォーマンスを使ったものがある [11]。しかし、この事例では、データの収集に高いコストを要する。これに対し、提案手法は、音声感情データのみを使用し、自動でオペレータの特徴を捉え、離職するかを予測する。

感情分析の分野では、Ching ら [6] は、Yelp に登録されたレストランのレビューに対して、アスペクトベースの感情分析と、1 年間の線形回帰を用いて顧客満足度を予測した。アスペクトベースの感情分析は、一つの文に複数のトピックが含まれる場合、どのトピックに着目するかで、その文における単語の重要度が変化することがある。この問題に対し、Liu ら [7] は、単語列の順序と、単語とアスペクトの相関を考慮したモデルを提案した。

DTW に関する研究として、Derivative DTW [9] があり、時系列データの要素を変換することにより、上昇トレンドや下降トレンドといった形状を考慮した類似度を算出する。また、shapeDTW [10] は、局所的に類似した構造のマッチングを行い、異なる構造に対してはマッチングを回避して類似度を算出する。本論文は、提案手法の有用性の検証に重きを置くため、ナイーブな DTW を使用する。

### 3 問題定義

この章では、本論文に使用するデータセットの説明と問題の定義を行う。表 1 に主な記号と定義を示す。今回用いるデータセットである  $n$  人のオペレータのデータ集合を  $\mathcal{D} = \{\mathcal{O}_1, \dots, \mathcal{O}_n\}$  とする。このとき、オペレータ  $i$  が持つ会話集合の集合を  $\mathcal{O}_i = \{C_1, \dots, C_{m_i}\}$  とし、 $m_i$  はオペレータ  $i$  の出勤日数を示す。また、会話集合  $j$  を  $\mathcal{C}_j = \{c_1, \dots, c_{l_j}\}$  とし、 $l_j$  は会話集合  $j$  に含まれる会話の数を示す。さらに、会話  $k$  を  $c_k^{(d)} = \{s_1^{(d)}, \dots, s_{u_k}^{(d)}\}$  と示す。このとき  $c_k^{(d)}$  は  $d$  次元時系列データで、 $u_k$  個の観測点を持ち、各観測点は  $d$  個の感情パラメータの値を持つ。感情パラメータの一部とその説明を表 2 に示す。また、各観測点  $s$  は開始点  $t_s$  と終了点  $t_e$  で構成され、 $s = \{t_s, t_e\}$  と示す。

**定義 1(クラスタリング結果)**  $\mathcal{F} = \{f_1, \dots, f_n\}$  を、 $n$  個の整数列とし、 $f_i$  はオペレータ  $i$  が属するクラスタ番号とする。例えば、オペレータ 1 がクラスタ 2 に、オペレータ 2 がクラスタ 1 に、オペレータ 3 がクラスタ 2 に属したとき、クラスタリング結果は、 $\mathcal{F} = \{2, 1, 2\}$  となる。

本論文の目的は、 $n$  人のオペレータのデータ集合  $\mathcal{D} = \{\mathcal{O}_1, \dots, \mathcal{O}_n\}$  が与えられたとき、クラスタリング結果  $\mathcal{F} = \{f_1, \dots, f_n\}$  を得ることで、在職者と離職者のクラスタに分けることである。これを、以下のように細分化して問題に取り組む。

**問題 1(データ整形)** 会話データ  $c^{(d)} = \{s_1^{(d)}, \dots, s_u^{(d)}\}$  が与えられたとき、 $c'^{(d)} = \{s_1'^{(d)}, \dots, s_L'^{(d)}\}$  に変換を行う。ただし、 $L$  は任意の自然数とする。

本手法では、会話同士の類似度の計算を行う。しかし、今回扱う会話データ  $c$  は、観測点の時間間隔が不均一で、データ長も異なり、扱いづらい。そこで、会話データ  $c$  を、観測点の時間間隔が均一でデータ長が  $L$  である  $c'$  へと変換を行う。

**問題 2(出勤日単位での代表会話の抽出)** 会話集合  $\mathcal{C} = \{c_1, \dots, c_l\}$  が与えられたとき、その日の特徴付ける会話  $c_\alpha$  を 1 つ抽出する。

表 1 主な記号と定義

記号	定義
$\mathcal{D}$	$n$ 人のオペレータのデータ集合 $\mathcal{D} = \{\mathcal{O}_1, \dots, \mathcal{O}_n\}$
$\mathcal{O}_i$	オペレータ $i$ が持つ会話集合の集合 $\mathcal{O}_i = \{C_1, \dots, C_{m_i}\}$
$m_i$	オペレータ $i$ の出勤日数
$\mathcal{C}_j$	出勤日毎の会話集合 $\mathcal{C}_j = \{c_1, \dots, c_{l_j}\}$
$l_j$	会話集合 $j$ に含まれる会話の数
$c_k^{(d)}$	長さ $u_k$ の $d$ 次元時系列データである会話 $c_k^{(d)} = \{s_1^{(d)}, \dots, s_{u_k}^{(d)}\}$
$u_k$	会話 $k$ のデータ長
$s_v^{(d)}$	$v$ 番目の観測値

表 2 感情パラメータの一部とその説明

パラメータ	説明
Energy	エネルギーの大きさを示す。 悲しみや疲労感、快適さ、精神的なさま、などを示す。
Stress	緊張を示す。
Embarrassment	不快感を示す。
Hesitation	快適さを示す。
Uncertainty	自信の度合いを示す。
Excitement	興奮や高揚を示す。
Concentration	集中の度合いを示す。

この処理により、オペレータが持つ会話集合の集合  $\mathcal{O} = \{C_1, \dots, C_m\}$  は、 $\mathcal{O} = \{c_{\alpha_1}, \dots, c_{\alpha_m}\}$  と表現できる。

**問題 3(オペレータ単位での代表会話の抽出)** オペレータが持つ会話のデータ集合  $\mathcal{O} = \{c_{\alpha_1}, \dots, c_{\alpha_m}\}$  が与えられたとき、そのオペレータを特徴付ける会話  $c_\beta$  を 1 つ抽出する。この処理により、オペレータのデータ集合  $\mathcal{D} = \{\mathcal{O}_1, \dots, \mathcal{O}_n\}$  は、 $\mathcal{D} = \{c_{\beta_1}, \dots, c_{\beta_n}\}$  と表現できる。

**問題 4(オペレータのクラスタリング)** オペレータのデータ集合  $\mathcal{D} = \{c_{\beta_1}, \dots, c_{\beta_n}\}$  が与えられたとき、クラスタリング結果  $\mathcal{F} = \{f_1, \dots, f_n\}$  を得る。

しかし、今回用いるデータは、離職者の数が少なく、離職者のクラスタを作るのは困難であると考えた。そこで、問題 4 を問題 4' へと修正し、新たな問題 5 を設定する。

**問題 4'(在職オペレータのクラスタリング)** 在職オペレータのみで構成される集合  $\mathcal{D}''$  が与えられたとき、クラスタリング結果  $\mathcal{F}''$  を得る。

**問題 5(離職懸念の有無の判定)** クラスタリング結果  $\mathcal{F}''$  が与えられたとき、テスト対象となるオペレータが離職懸念を持つ可否かの判定をする。

### 4 提案手法

本論文では、複数のオペレータの音声感情データが与えられたとき、離職懸念を抱えるオペレータを特定する手法を提案する。第 3 章で設定した問題に沿って、提案手法のアルゴリズムの説明を行う。

#### 4.1 手順 1(データ整形)

データの整形の手順を以下に示す。

1. 会話データ  $c = \{s_1, \dots, s_u\}$  において、観測点  $s_i$  の観測時刻  $t_i$  を  $t_i = \frac{t_s + t_e}{2}$  と定義する。このとき会話データ  $c$  の各観測点の時刻は  $\{t_1, \dots, t_u\}$  と表現される。
2. 会話の長さを 1 にする。つまり、 $\{t_1, \dots, t_u\}$  を、 $\{0, \dots, \frac{t_u - t_1}{L}, \dots, 1\}$  に変換する。
3. 時刻  $(\frac{j}{L}, \frac{j+1}{L})$  (ただし、 $j$  は  $0 \leq j < L$  を満たす整数) に含まれる観測点について、観測値と観測時刻の平均を算出する。このとき、該当する観測点が存在しないこともある。
4. 時刻  $\frac{k}{L}$  (ただし、 $k$  は  $0 \leq k \leq L$  を満たす整数) に該当する観測値を、3. で求めた値をもとに、最近傍点の加重平均として算出する。

#### 4.2 手順 2(出勤日単位での代表会話の抽出)

出勤日単位での代表会話の抽出の手順を以下に示す。

1. ある出勤日の会話集合  $C = \{c_1, \dots, c_l\}$  において、サイズ  $(l \times l)$  の DTW 行列を算出する。
2. 行 (または列) 方向に合計を取った長さ  $l$  のリストを算出する。
3. 最小値を取るインデックスを、代表会話  $c_\alpha$  とする。

上記の手法は、複数ある会話の集合から、最も中心にある会話を選択している。この処理を行うことで、ノイズとなる会話を除き、また、1 日の気持ちの遷移に影響されない、その日を特徴付ける会話の抽出を行う。

#### 4.3 手順 3(オペレータ単位での代表会話の抽出)

第 4.2 節の処理により、オペレータが持つ会話集合の集合  $\mathcal{O}$  は、 $\mathcal{O} = \{c_{\alpha_1}, \dots, c_{\alpha_m}\}$  となり、これは単なる会話集合として扱うことができる。すなわち、第 4.2 節と同様の手順でオペレータ単位での代表会話の抽出が可能である。代表会話の抽出の手順を以下に示す。

1. オペレータが持つ会話集合の集合  $\mathcal{O} = \{c_{\alpha_1}, \dots, c_{\alpha_m}\}$  において、サイズ  $(m \times m)$  の DTW 行列を算出する。
2. 行 (または列) 方向に合計を取った長さ  $m$  のリストを算出する。
3. 最小値を取るインデックスを、代表会話  $c_\beta$  とする。

ここまでの処理によって、オペレータをある一つの会話として表現することができ、オペレータ同士の類似度の計算も可能となる。

#### 4.4 手順 4'(在職オペレータのクラスタリング)

第 4.3 節の処理により、オペレータ集合  $\mathcal{D}$  は、 $\mathcal{D} = \{c_{\beta_1}, \dots, c_{\beta_n}\}$  と表現でき、単なる会話集合として扱うことができる。在職オペレータのみの集合を  $\mathcal{D}'$ 、在職オペレータの数を  $n''$  とする。クラスタリングの手順を以下に示す。

1. 在職オペレータの集合  $\mathcal{D}'$  において、サイズ  $(n'' \times n'')$  の DTW 行列を算出する。

2. DTW 行列をもとに k-means 法によりクラスタリングを行う。

この処理によって、似たオペレータ同士をグルーピングする。

#### 4.5 手順 5(離職懸念の有無の判定)

離職懸念の有無の判定の手順を以下に示す。

1. あるクラスタに含まれるオペレータ集合において、DTW 行列を作成する。
2. 行 (または列) 方向に合計を取ったリストを算出する。
3. 最小値を取るインデックスを、そのクラスタの中心のオペレータとする。
4. クラスタ中心のオペレータと最も離れたオペレータとの距離を算出する。この値を  $d_1$  とする。
5. クラスタ中心のオペレータとテスト対象のオペレータとの距離を算出する。この値を  $d_2$  とする。
6.  $d_2 < d_1$  の時、テスト対象のオペレータは在職オペレータのクラスタに属するとし、離職懸念なしと判断する。反対に、条件を満たさない場合は、テスト対象のオペレータは離職懸念ありと判断する。
7. 1. から 6. の処理を全てのクラスタに対して行う。

## 5 実験

実データを用いて、提案手法の実験を行う。

### 5.1 実験設定

この節では実験に使用するデータセットの説明と実験の進め方について述べる。

[データセット]

データセットは、在職者が 25 人、離職者が 3 人含まれる合計 28 人で構成される。いずれのオペレータも同じ業務窓口を担当する。

[予測の正解の定義]

予測の正解の定義を下記のように定義する。

- ・ 在職者の正解とは、対象者がいずれかのクラスタに属することである。
- ・ 離職者の正解とは、対象者がいずれのクラスタにも属さないことである。

[変数・パラメータの設定]

本手法は、データ整形後のデータの長さ  $L$  と、解析に使用する感情パラメータを設定する必要がある。今回の実験では  $L = 50$  とし、感情パラメータは “Energy” を使用する。

[交差検証]

25 人の在職者のデータセットをトレーニングデータとテストデータに分割して交差検証を行う。このとき、テストデータを 3 人、残りをトレーニングデータとして合計 9 回実験を行い、評価を行う。3 人の離職者のデータセットは毎回テストデータとして扱う。

### 5.2 実験結果

クラスタ中心のオペレータと最も離れたオペレータとの距離

$d_1$  と、クラスタ中心とテスト対象のオペレータとの距離  $d_2$  を算出した結果の一部を表 3 に示す。ここで、 $d_1 > d_2$  を満たすテストデータは赤字で示しており、これらは在職者クラスタに属すると判断されたものである。また、各クラスタの  $d_1$  を見ると、クラスタ 2 のように高い数値を示すものがある。このようなクラスタはクラスタ数を変更させた場合にも出現した。

表 3 クラスタ中心と対象のオペレータとの DTW 距離

	$d_1$	在職者			離職者		
		test1	test2	test3	test4	test5	test6
クラスタ 1	0.0340	0.0967	0.0149	0.0299	0.0348	0.0553	0.0912
クラスタ 2	0.1196	0.0742	0.1167	0.0847	0.0627	0.0751	0.0640
クラスタ 3	0.0435	0.0394	0.0472	0.0726	0.0614	0.0523	0.0502
クラスタ 4	0.0195	0.1600	0.0207	0.0574	0.0587	0.0967	0.1207

次に、正解率について表 4 から表 7 にまとめる。ただし、大きな  $d_1$  を示すクラスタは無視した結果である。

表 4 クラスタ数 3 の正解率

テストデータ	正解率
在籍者	0.778
test4	0.000
test5	1.000
test6	1.000
離職者全体	0.630

表 5 クラスタ数 4 の正解率

テストデータ	正解率
在籍者	0.741
test4	0.333
test5	1.000
test6	1.000
離職者全体	0.778

表 6 クラスタ数 5 の正解率

テストデータ	正解率
在籍者	0.778
test4	0.111
test5	0.889
test6	0.889
離職者全体	0.630

表 7 クラスタ数 6 の正解率

テストデータ	正解率
在籍者	0.667
test4	0.222
test5	0.889
test6	0.889
離職者全体	0.667

### 5.3 考察

まず、離職者の正解率について、常に高い正解率を示すオペレータもいれば、常に低い正解率を示すオペレータも存在した。後者については、離職原因を突き合わせてみると、業務不満とは関係のない理由であることがわかった。次に、在職者の正解率について、常に不正解になるオペレータが数名いることがわかった。これらのオペレータの内の一部は、管理者から見て離職懸念がありそうだと、思われているオペレータも含まれていた。業務不満とは関係ない理由で離職したオペレータの扱いと、在職ではあるが離職懸念を抱えているオペレータをトレーニングデータとして使ってしまった、ということは今後の課題となる。

次に、大きな  $d_1$  を持つクラスタが発生したことについて、k-means 法が外れ値に弱く、特異的なオペレータに影響されたのではないかと考えられる。ここでの特異的なオペレータとは、出勤日数が少なく代表会話の抽出がうまくいかなかった者や、今回サンプルが少なく、同じクラスタに属するものが他にいな

かった者、そもそも人とは異なった会話をする者のことである。結果を見ると、そのクラスタを生成する要因となるオペレータは固定されており、このようなオペレータに対し、うまく対処する必要がある。今後は、要因となったオペレータのデータを見直して原因を追求しつつ、外れ値に堅牢な手法を考案するつもりである。

### 5.4 追加実験

データ提供をしていただいた方から、クラスタリング結果は、オペレータの性格ごとに分かれているかもしれないとのアドバイスを受け、追加で実験を行った。

#### [データセット]

在職者と離職者を含む 126 人で構成される。各オペレータには手動でラベリングづけがされている。ラベルの種類は“感情”、“感情・論理”、“論理”の 3 タイプである。

#### [実験方法]

同様の手順で実験を行い、得られたクラスタリングの結果とラベルの関係について考察する。

#### [実験結果]

クラスタ数を 6 としたときの結果を表 8 にまとめる。

表 8 各クラスタに含まれるタイプ別の人数

	クラスタ 1	クラスタ 2	クラスタ 3	クラスタ 4	クラスタ 5	クラスタ 6
感情	0	21	0	10	7	0
感情・論理	0	0	4	20	0	0
論理	22	0	4	32	1	5

例えば、クラスタ 1 だと“論理”タイプが 22 人含まれ、クラスタ 3 だと“感情・論理”タイプが 4 人と“論理”タイプが 4 人含まれている。

#### [考察]

クラスタ毎にタイプの偏りが出た結果となった。ただし、クラスタ 4 に関しては、複数のタイプが存在し、また、要素数もかなり大きくなった。この原因についてはまだわかっていない。しかし、オペレータをタイプ毎にまとめることができれば、マネジメントの可能性は広がると考えられる。また、オペレータが在職者と離職者ではなく、性格ごとに分類された原因として、本手法が長期間の出勤日の中からたった 1 会話を選択するため、現在の特性よりも、長期的な特性である性格を強く反映したことが考えられる。

## 6 終わりに

本論文では、音声感情データを解析することにより離職懸念を抱えるオペレータを特定するという問題に取り組んだ。実験では、提案手法は、高い精度を示し、何かしらの有用性を示す結果となった。今後はデータを増やしつつ、様々なケースに対しての有用性を検証していく必要がある。また、オペレータの長期的な特性ではなく、最近の特性を捉える工夫についても考える必要がある。

## 謝 辞

データのご提供とともに、貴重なアドバイスをいただいた  
CENTRIC 株式会社様に感謝の意を表す。

## 文 献

- [1] Gilad Mishne, David Carmel, Ron Hoory, Alexey Roytman, and Aya Soffer, "Automatic Analysis of Call-center Conversations," In CIKM, pp. 453–459, October 2005.
- [2] 那須川哲哉, "コールセンターにおけるテキストマイニング," 人工知能学会誌, Vol.16, No.2, pp. 219–225, 2001.
- [3] 伊藤稔稔, "コールセンターにおけるインバウンド予測," Unisys 技報, Vol.87, No.5, pp. 19–30, 2005.
- [4] 田原琢士, 王軼福, 山浦佑介, 大西健司, "コールセンターを対象とした業務量予測に関する研究," 第 31 回人工知能学会全国大会, 2017.
- [5] リックテレコム. "コールセンター白書 2018." コールセンタージャパン, 2018.
- [6] Michelle Renee D. Ching and Remedios de Dios Bulos, "Improving Restaurants' Business Performance Using Yelp Data Sets through Sentiment Analysis," In ICEEG, pp. 62–67, June 2019.
- [7] Qiao Liu, Haibin Zhang, Yifu Zeng, Ziqi Huang, and Zufeng Wu, "Content Attention Model for Aspect Based Sentiment Analysis," In WWW, pp. 1023–1032, April 2018.
- [8] Jeong, Young-Seon, Myong K. Jeong, and Olufemi A. Omitaomu. "Weighted dynamic time warping for time series classification," In Pattern Recognition, Vol.44, No.9, pp. 2231–2240, September 2011.
- [9] Eamonn Keogh and M.J. Pazzani, "Derivative dynamic time warping," In SDM, 2001.
- [10] L. I. J. Zhao, "shapeDTW: Shape Dynamic Time Warping," In Pattern Recognition, Vol.74, pp. 171–184, 2018.
- [11] ITmedia, "コールセンターの退職予備軍を AI で予測し、半年で離職者を半分にできた理由," ITmedia エンタープライズ, 2018 年 9 月 5 日公開, 最終閲覧日 2020 年 1 月 8 日, <https://www.itmedia.co.jp/enterprise/articles/1809/05/news001.html>