

# ユーザー体験に基づく個人化観光推薦システムの提案

山岸 立† 馬 強††

† 京都大学大学院 情報学研究科 〒 606-8501 京都府京都市左京区吉田本町

†† 京都大学大学院 情報学研究科 〒 606-8501 京都府京都市左京区吉田本町

E-mail: †yamagishi@db.soc.i.kyoto-u.ac.jp, ††qiang@i.kyoto-u.ac.jp

あらまし 個人に適応した観光を実現するため、ユーザがいつ、どこで何をしたいかといったユーザ体験や目的を明らかにすることが重要である。そこで本論文では、Flickr や Instagram などの投稿を対象にユーザの嗜好を分析する確率モデルとそれに基づくユーザの求める観光体験を推薦するシステムを提案する。提案システムでは、ユーザ体験の四要素 (Who, When, Where, What) をモデリングし、ユーザの行動データに応じて逐次的にユーザの嗜好を推論しながら観光スポットや観光体験を推薦する。

キーワード 観光, 推薦システム, トピックモデル, 確率モデル, 逐次推論

## 1 はじめに

観光において、多くの人は雑誌や旅行サイトで有名な観光場所を探し、その場所をたどり、その場所で行きたくないことをすることが多い。また、近年 SNS が普及し、人々が自らの生活の一部を公開することが多くなった。特に Instagram や Flickr などの写真を主として投稿する SNS では若者を中心におしゃれな写真をとることが多くなり、写真の対象もそのオリジナリティとクオリティを追求するようになった。つまり、人々は観光としての体験にオリジナリティとクオリティを求めており、そのような「個」としての体験を如何に実現するかということを考えるようになってきている。

例として京都に観光に行くとする。Google で「京都 観光」と検索すると有名な観光地のリストがその地図上の場所とともに表示されるこれは誰が検索しても同じ結果を示し、個々人のユーザに特化した検索結果ではない。京都にすでに住んでいる地元の人も日本に初めて来る外国人も同じ結果が示される。また、食べ歩きが好きな人も寺社をじっくり見たい人も同じ結果が示される。体験としてのオリジナリティを見つけることが困難な状況である。「個」としての体験を見つけるためには場所を基準とするより、場所の特性も考慮しながらその場所のできる特別な体験を基準として考えることが重要である。

本研究では体験のある場所で行う行動とし、[7] で示されている通り、四つの要素からなるとする。四つの要素は行動の主体を表す Who, 時間を表す When, 場所を表す Where, そして行動自体をあらわす What である。この四要素を考慮することで、誰がいつどこで何をしたいかという体験の具体的な部分を表すことができる。本論文では、この四つの要素をトピックモデルを用いて分析することでその人の趣味嗜好および場所の特性を考慮して、複数の体験を推薦する手法を提案する。

本論文における貢献は以下である。

- Instagram や Flickr に公開されている画像とそのメタデータを用いて、ユーザの体験を分析する確率

モデルを提案する。

- ユーザを複数グループに分割し、そのグループごとにその人々の趣味嗜好との関係を確率的に分析する。これにより個々の観光客のデータが少ない、いわゆるコールドスタート問題を緩和する。
- ユーザ体験を分析する確率モデルの逐次推論手法を提案する。ユーザの新しいデータを加えることで逐次学習を行い、よりユーザの趣味嗜好に合わせて推薦を行う。

以下では、2 節で関連した研究を紹介し、3 節で提案手法を示す。次に提案手法を応用したアプリケーションを 6 節で説明する。最後に 7 節でまとめと今後の課題について述べる。

## 2 関連研究

Q. Yuan らは Twitter を対象にユーザの行動を分析するモデルを提案している [7] [8]。この研究ではユーザの行動を Who, Where, When, What で分割し、Twitter のデータを利用して行動分析および予測を行っている。Yuan らの手法は、日常生活でたくさん発信される位置情報付きの情報を対象としているが、データ量が少ない観光では適用困難である。そのため、我々のモデルでは似た行動をするユーザをグループ化し、それを表現する潜在変数をモデルに導入している。

普段の生活圏では決まった行動を取りやすいが、観光においては全く異なる行動指針によって動く。実際に [3] では普段の行動の軌跡の情報量を測ることで最大 93% の精度で行動予測できることを述べている。また、同時に旅行時の行動は大きな違いがあることも述べている。故に同じ Point of Interest (POI) の分野でもその普段の行動であるかどうかを見ることが重要となる。特に [2] では、POI の分野で普段の行動かどうか、つまり in town か out of town かによって多くの研究が整理され、まとめられている。

観光の行動予測で最も問題となるのが、同じユーザでの再現性の少なさである。観光においては同じ場所に何回も行くこと

が少ない。旅行できて、特定の観光地を転々と観光し、その後は一度も来ないということは少なくない。つまり、ユーザと場所の関係はスパースなものとなりやすく、データの扱いに注意が必要となる。[6] ではそのような問題に取り組み, in town と out of town どちらにも対応できるようなモデルを作っている。

[5] [9] [11] [10] では、データがスパースになる問題に加え、コールドスタート問題に陥ってしまうことに対してグループという概念を入れることによって対応している。グループを入れることで、一人のユーザのデータが少なくてもグループ全体で特徴が捉えられていれば、最適な推薦をすることができる。これに習って、本研究もユーザをグループに分割し、グループごとに趣味嗜好を捉える。

### 3 提案手法

この節では実際に観光体験を推薦するための手法を説明していく。まず最初に 3.1 節でモデルを構築するための基本的な観測、次に 3.2 節でモデルの詳細、最後に 3.3 節ユーザの操作に基づく逐次推論について説明していく。

#### 3.1 観測

本論文では次の三つの観測を元に観光地でのユーザの行動をモデリングする。

**観測 1** 趣味嗜好が似ている人は複数人いる。つまり、趣味嗜好 (以降トピック) を基準にユーザをいくつかのグループにクラスタリングできる。逆にグループは複数のユーザを持ち、特定のトピックを持つことになる。例えば、あるユーザ A とあるユーザ B の趣味嗜好が似ている場合、A と B は同じグループに属し、A がある場所である行動を好むのならばそれが B にも当てはまる可能性が高いということである。

**観測 2** 場所はトピックにしたがって決定される。トピックが同じならば同じ場所に行く確率は高まり、同じ確率分布からその確率は決まる。しかし、場所はただ一つのトピックに所属するのではなく、複数のトピックからその場所が決定される可能性がある。

**観測 3** 場所、トピックが決まった場合、その場所でする行動は一つとは限らない。実際に実験では、イメージを表すタグを用いて行動を示す単語として扱う。

#### 3.2 ユーザ体験を分析するモデル

3.1 節で説明した観測を踏まえて、モデルを定義する。図 1 にモデルのグラフィカルモデルを示す。また、記号の定義を表 1 に示す。

本モデルでは、ユーザ、場所、行動を表す単語を観測変数として扱い、主にグループとグループごとのトピックつまり趣味嗜好を潜在変数とする。ここからは生成過程を説明していく。

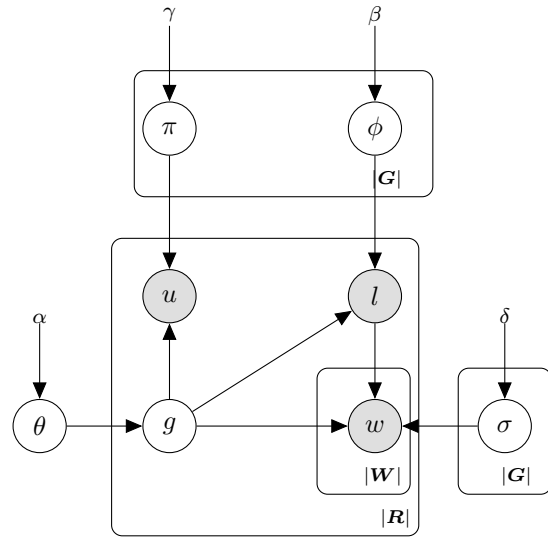


図 1: 提案モデルのグラフィカルモデル

表 1: 記号の定義

記号	定義
$G$	グループの集合
$R$	投稿の集合
$W$	行動を示す単語の集合
$ G $	グループ数
$ R $	投稿数
$ W $	行動を示す単語数
$N_r$	ある投稿 $r(\in R)$ での行動を示す単語数
$u$	ユーザ
$g$	グループ
$z$	トピック
$l$	位置情報
$w$	行動を示す単語
$\theta$	グループを与えるカテゴリ分布
$\pi$	グループごとのユーザの生成確率分布
$\phi$	グループごとの位置情報の生成確率分布
$\sigma$	グループ、投稿が決まった時の行動を示す単語の生成確率分布
$\alpha, \beta, \gamma, \delta$	ハイパーパラメータ

アルゴリズムを Algorithm1 に示す。  $\theta$  はグループを生成する確率分布であり、ハイパーパラメータ  $\alpha$  をパラメータとしてとるディレクレ分布から生成される。故にその関係は、

$$\theta \sim \text{Dir}(\alpha)$$

となる。

ここからはある投稿データ  $r(\in R)$  の元で生成していく。グループの生成確率分布からグループ  $g_r$  を生成し、  $g_r \sim \text{Multinomial}(\theta)$  と表せる。ここでのグループは潜在変数であり、ユーザの趣味嗜好が含まれることになる。投稿データのプレート上にあるのはその投稿データのユーザ、場所、行動へのマッピングの役目をするからである。

次に、ユーザはグループから生成されると考えることができるので (観測 1),  $u_r \sim \text{Multi}(\pi_{g_r})$  の関係が成り立つ。ただしこの時、  $\pi_{g_r}$  はハイパーパラメータ  $\gamma$  から生成され、  $\text{Dir}(\gamma)$

**Algorithm 1** 生成過程

---

```

1:  $\theta \sim \text{Dir}(\alpha)$ 
2: for  $g$  in  $|G|$  do
3:    $\pi_g \sim \text{Dir}(\gamma)$ 
4:    $\phi_g \sim \text{Dir}(\beta)$ 
5:    $\sigma_g \sim \text{Dir}(\delta)$ 
6: end for
7: for  $r$  in  $|R|$  do
8:    $g_r \sim \text{Multinomial}(\theta)$ 
9:    $u_r \sim \text{Multinomial}(\pi_{g_r})$ 
10:   $l_r \sim \text{Multinomial}(\phi_{g_r})$ 
11:  for  $n$  in  $N_r$  do
12:     $w_{r,n} \sim \text{Multinomial}(\sigma_{g_r})$ 
13:  end for
14: end for

```

---

に従う。同様に位置情報もグループごとの位置情報の生成確率分布  $\phi_{g_r}$  から生成され、

$$l_r \sim \text{Multi}(\phi_{g_r})$$

$$\phi_{g_r} \sim \text{Dir}(\beta)$$

が成り立つ。最後に行動を示す単語は  $w_{r,n}$  で表しているが、この変数が単独でプレートに載っていることから、ユーザや位置情報が決まる投稿に対して、行動は複数 ( $N_r$  個) 存在することを示している (観察 3)。 $w_{r,n}$  はグループが決まればその確率分布が決まるので、 $w_{r,n}$  の生成確率分布は  $\sigma_g$  と表され、これはハイパーパラメータ  $\delta$  はパラメータととるディレクレ分布  $\text{Dir}(\delta)$  に従う。

### 3.3 逐次推論

推薦システムにおいてはユーザの操作によって逐次的に推論を行い、よりユーザの趣味嗜好にあった推薦ができるように更新していく。クリックや推薦へのフィードバックによってユーザの操作が発生した時、そのデータはユーザの興味を意味する。そのデータをユーザの確率分布を更新することで、よりユーザの趣味嗜好に合ったグループに所属する可能性が高まり、精度の良い推薦がきたいできる。

## 4 実験

この節では提案モデルの評価実験を行う。最初にデータセットについて述べ、その後実験計画、結果について述べていく。

### 4.1 データセット

Instagram や Flickr の情報は投稿自体に Who, When, Where, What の四つの情報が含まれている。アカウント自体が Who を表し、投稿の時間が When, 付加された位置情報が When, 最後に写真に行動が示されている。故に体験を分析するにはこのようなデータが最適であり、実際に実験では Yahoo Flickr Creative Commons 100M(以下 YFCC) [4] を使って行った。YFCC は過去の Flickr のデータが大量に存在し、世界中の写真とそのメタ情報が提供されている。今回はそのデータを

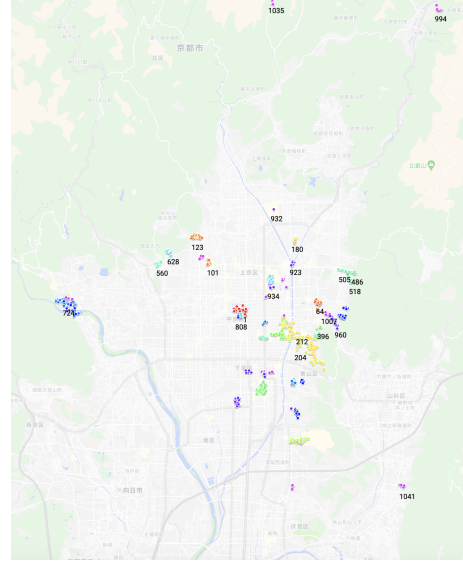


図 2: クラスタリング後の場所の配置

京都市内のデータに限定し、提案モデルの観測データとして扱う。実際のデータ数は以下の表 2 に示す。

表 2: データの概要

データの種類	データ数
ユーザ	915
場所	1065
タグの種類	2659
総タグ数	372599
データ数	37469

YFCC で得られるメタ情報の中で場所の情報は緯度・経度とその場所の住所がある。その中で緯度・経度を使い、クラスタリングを行う。というのも緯度・経度をそのまま使用すると同じ場所として認識されることがほぼなくなってしまう、全て異なる場所になってしまうことを避けるためである。それゆえ、先行研究 [12] で用いられた DBSCAN を元にしたクラスタリングを行い、さらにクラスサイズが大きかったため Mean Shift を用いてクラスタリングを実行した。表 2 で示されてる場所の数はクラスタの数である。クラスタリングした時にクラスの代表点が決まるのでそれを地図にマッピングすると図 2 となる。マッピングには Google My Map を用いた。

また、タグに関して YFCC では写真ごとにタグ付がなされている。一つの写真について以下の 3 種類のタグ付がなされている。

**ユーザがつけるタグ** ユーザが投稿の際につけるタグである。ユーザがつけるタグに制限はなく、自由にタグを付け加えることができる。

**機器がつけるタグ** カメラやコンピュータ、その他自動システムによって自動的につけられたタグである。

**画像認識によってつけるタグ** これは Bart らが畳み込みニューラルネットワークを用いて画像認識をし、タグ付したものである。メタ情報自体は単数または複数のタグとそ

れぞれについて検出確率がついている。

実験に用いるデータセットでは以上の3つのタグが全て存在しないデータは省いた。基本的には画像認識によってつけるタグを用いて、そのタグがない場合はユーザがつけるタグを用い、どちらもない場合に機器がつけるタグを用いた。

## 4.2 実験計画

今回の実験では上記のデータセットを用いてユーザ体験の分析を行う。提案モデルの学習では The No-U-Turn sampler [1] を用いて行う。ハイパーパラメータである  $\alpha, \beta, \gamma, \delta$  はそれぞれ一様分布を用い、初期値は  $1/(\text{要素の長さ})$  とする。以上4つのパラメータの他に与えるデータとしてはグループの数が存在する。グループはユーザのトピックを表すのでその数は評価に大きく影響してくる。今回の実験ではグループ数を 5, 15, 30, 50 で実際に試しており、どのような影響が出るかをみた。

また、実装には PyStan を用いて行った。基本的にサンプリング数は 1000 回とし、バーンイン期間を 500 回としている。

## 4.3 評価

ここでの評価は提案モデルがユーザの行動をどれほど分析できているかを示す指標である。提案モデルではグループを入れることでユーザのトピックを抽出し、その人に合わせた場所、行動を薦めるというものであった。このことから以下の2点の指標を軸に評価を行う。

- ユーザに対して適切な場所が推薦できてるか
- グループに対してトピックを抽出できてるか

### 4.3.1 ユーザに対して適切な場所が推薦できてるか

ユーザに対して適切な場所が推薦できてるかに関しては求めた事後分布を元にそのユーザが行きやすい場所をスコアリングし、ランキングを生成する。具体的に述べると、学習を行うと、以下の事後分布が得られる。

$$u_r \sim \text{Multinomial}(\pi_g) \quad (1)$$

$$l_r \sim \text{Multinomial}(\phi_g) \quad (2)$$

ただし、 $r \in \mathbf{R}, g \in \mathbf{G}$  である。この時、あるグループ  $g$  においてあるユーザ  $u \in \mathbf{U}$  が  $l \in \mathbf{L}$  に行く確率  $p(u, l|g)$  は、

$$p(u, l|g) = p(u|\pi_g)p(l|\phi_g) \quad (3)$$

となる。これはユーザと場所が条件付き独立であることから成り立つ。それゆえ、 $g$  を周辺化して、グループに関係なく、あるユーザ  $u$  がある場所  $l$  に行く確率  $p(u, l)$  は、

$$p(u, l) = \sum_{g=1}^{|\mathbf{G}|} p(u, l|g) \quad (4)$$

$$= \sum_{g=1}^{|\mathbf{G}|} p(u|\pi_g)p(l|\phi_g) \quad (5)$$

が成り立つ。この計算をすることで、ユーザごとに行く確率の高い場所のランキングを作成することができる。実験の評価ではデータ  $r$  に対して  $u_r$  と  $l_r$  が定まり、 $u_r$  の行く確率の高い

表 3: 実験結果と場所推薦の評価

実験番号	グループの数	トップ 1 の数	トップ 10 の数
1	5	1404	7486
2	15	1722	7777
3	15	2323	9164
4	30	1397	6593
5	50	1954	7031

場所のランキングにおいて、トップに入るか、またはトップ 10 に入るかの二つを指標とした。

### 4.3.2 グループに対してトピックを抽出できてるか

トピックの評価に対しては WordCloud を用いる。この評価に関しては定量的な判断ではなく、うまく同じ分野の単語がグループごとに分けられているかを判断する。具体的には  $\sigma$  のタグの生成確率を元にタグの WordCloud を作成する。グループごとにタグの生成確率が高い順に文字が大きく表示されるようになっている。

## 4.4 実験結果

### 4.4.1 結果

節 4.3 で述べた者のうち、ユーザに対して適切な場所が推薦できてるかを表 3 に示す。

グループの数を基準に実験番号を振っている。それぞれ、5, 15, 30, 50 のグループにわけ、グループの 15 に分ける時のみ二回実験を行っている。これは同じグループ数に分けたときでも評価に影響が出るのを見るためである。トップ 1 の数というのは各投稿データについて、そのデータの場所がそのデータのユーザが行く確率が高い場所のランキングで何位なのかを求めた者のうち、上位 1 位だったものの数である。トップ 10 の数は同様の数え方で上位 10 位出会った者の数を示す。

どの実験に対しても同じデータを用いており、その投稿データ数は 37469 である。また、サンプリング回数も 1000 回でバーンイン期間を 500 としている。また、全てマルコフ連鎖の数は 2 となっている。サンプリング後に収束判断をする際に用いる Rhat の値であるが、実験番号 1 の実験では全てのパラメータで 1.1 以下になっており、収束していることが確認された。しかし、他の実験では Rhat の値が大きくなってしまいうパラメータも存在した。

上記のトップ 1 とトップ 10 の精度の総データ数に対する百分率をマッピングしたものを図 3 に示す。図 3 では横軸をグループ数、縦軸を精度としてデータをマッピングした。また、散布の様子を元に線形のトレンドラインを引いた。

次にもう一つの評価であるグループに対してトピックを抽出できてるかを WordCloud で示していく。良くトピックを捉えることができた例とできなかった例を図 4 と図 5 に示す。図 4 は実験番号 3 の group3 のタグの生成確率をもとにしたものである。この図では植物を中心に自然に関係するものが集まっている。また、図 4 は実験番号 2 の group7 のタグの生成確率をもとにしたものである。この図では生成確率が高いタグが少ないばかりか、あまり関連がないように見える単語が並んでいる。

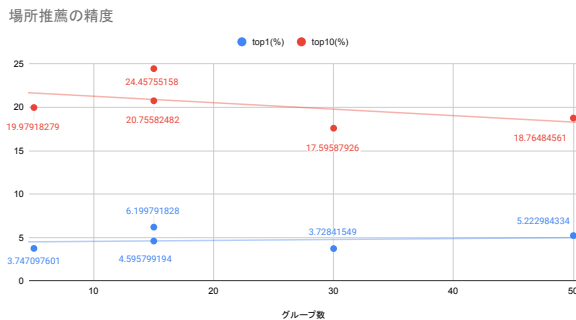


図 3: 場所推薦の精度




図 7: 実験番号 3 の実験における上位 40 位の数の推移




図 4: トピックを捉えていた例






図 5: トピックを捉えきれなかった例




## 実験番号 2 のグループ 8



実験番号 3 のグループ 8



実験番号 4 のグループ 5



実験番号 5 のグループ 2

図 6: 飲食関係のグループ

傾向としてはやはりグループの数が増えれば増えるほど、関連がないように思えるタグで構成されるグループが出てくることや全く同じような傾向をもつグループが複数存在することが多くなった。逆にグループが5のときは一つのグループに複数のトピックが含まれているかのように色々な分野のタグが入っていた。

グループ数に関係なく一定なことも存在し、それは飲食に関するタグは関連性が強く、同じグループに属するということがわかった。図 6 は総グループ数が異なっても同じような単語が生起されて同じグループに属することが多いことを示している。

## 5 考 察

まず, Rhat の値から考察していく. Rhat は収束判断の際に使われ, 1.1 以下である場合に収束していると判断できる. しかし, 今回は実験番号 1 でのみ収束した状態と考えられるので

実験 2 以降ではサンプリング回数が少ないと思われる。

次に表??と図3について考察していく。精度に関してはグループが15の結果の時に最も良くなっている。ループ数が15の実験は実験番号2と実験番号3の二回行われており、その値も全く同じものとは言えないが、どちらも他のグループ数の時の水準を上回っており、15の付近に最適なグループ数があるものと考えられる。

また、トップ1とトップ10の関係について考えていく。トップ1もトップ10もそれほどグループの数に対してほぼ同様の動きをしている。グループ数が15が最も高い状態であり、グループ数が少なすぎても多すぎても精度が悪くなるというものである。この傾向は WordCloud の方にも見られ、グループが少なすぎるといくつかの分野のタグが入ってしまい、グループが多すぎると同じようなグループであったり全く関連のないタグが少数でグループを形成してしまうことがある。

図 7 に実験番号 3 の各投稿データについてそのユーザが行きたい場所のうちその投稿データが何位であるのかを上位 40 位をヒストグラムで表したものである。この図を見ると、上位 1 位が最も多く、徐々に減っていきロングテールの形をなしていることがわかる。つまりグラフの形からは各データに対してそれぞれのユーザに対して行く確率の高い場所を提供できていることがわかる。

しかし、全体的に上位 1 位の精度は最高でも 6% とかなり低い水準となってしまっている。上位 10 位にであっても 24% となっており、これはユーザに対してオススメの場所 10 を提供したとして、実際に行く場所を 24% の確率でしか提供するリストに入っていないことを意味する。今後は収束しているかを含め、さらに精度を高めるためにモデルの構成を考えることが必要である。

## 6 アプリケーション

本論文ではこの提案モデルを利用したアプリケーションを設計した。このアプリケーションでは実際にユーザに観光地を選んでもらい、趣味嗜好を考慮しながら観光体験の推薦を行う。主な機能としては観光体験の推薦の他に、趣味嗜好を知るためのアンケートおよびグループの推論である。以下、ユーザインターフェースと実際の機能の詳細について説明する。





図 8: 初期アンケート画面



図 9: 推薦画面

## 6.1 ユーザインターフェース

開発アプリケーションは二つの画面からなる。

1つ目は初期アンケートを行う画面で、ユーザがアプリケーションを訪れた時に最初に表示する。初期アンケート画面ではユーザはいくつかの画像を見て、興味の度合いをそれぞれの画像に対してフィードバックする。その結果をもとにユーザの属する情報を判断する。

2つ目は推薦を行う画面であり、ここでユーザは観光体験の推薦を行う。推薦画面では、左側に推薦された観光体験がリストで表示されており、ユーザはクリックしたり、再推薦を行うことができる。また、観光場所のデータが地図上に全てマッピングされており、ユーザは選ぶことができる。

初期アンケート画面は最初のみでそれ以降は主に推薦画面での操作となる。

## 6.2 アプリケーションの機能

アプリケーションの機能としては主に観光体験の推薦とグループの推論に分かれる。そしてこの主な2つの機能は2つのエンジンに分けて実現している。観光体験を推薦する機能を担う方をベースエンジン、グループの推論をする機能を担う方を推論エンジンとする。ベースエンジンは3.2節のモデルを構築、実現する。推論エンジンは3.3節の逐次推論手法を実装する。以降それぞれのエンジンにわけて説明していく。

### 6.2.1 ベースエンジン

ベースエンジンでは、主に提案手法で説明したモデルを用い

て観光体験の推薦を行う。入力自体はユーザのIDのみを受け付ける。そのユーザの属するグループは推論エンジンによって推論されるので、データベースを読み出すことによってユーザの属するグループを把握することができる。故にグループがわかったので、モデルに当てはめることでそのグループのトピックの分布、および場所、行動を示す単語の生成確率分布を取得できる。あとは確率的に高い順にスコアリングし、推薦に出力することができる。出力自体は位置情報、行動を示す単語のリストとなる。

### 6.2.2 推論エンジン

推論エンジンではアプリケーションに訪れたユーザがどのグループに属するかを推論する役割をもつ。ここでいうグループとは、すでに提案手法で示したモデルの学習があらかじめ終了しており、学習データのユーザがクラスタリングされたものである。推論エンジンが推論をするタイミングは複数存在する。

まず初めに初期アンケートの時に推論を行う。初期アンケートはコールドスタート問題に対応するもので、いくつかの画像を見せてユーザにそれぞれの画像に対してフィードバックをしてもらう。実際に見せる画像はグループごとの代表的な画像となっており、そのフィードバックをベクトルとして入力する。推論はグループごとのアンケート画像の生成確率のベクトルと類似度をはかり、スコアの高いものとする。

次に、推薦画面でユーザが観光体験をクリックしたときである。クリックしたということはユーザがその体験に興味を示したことを表す。この時にユーザの属するグループのその体験に対する生成確率と他のグループの確率を比べる。

最後に推薦自体のフィードバックした時に推論を行う。推薦した体験一つ一つにフィードバックをしてもらい、そのベクトルを入力とする。推論の仕方自体は初期アンケートと同じである。

以上3つのタイミングで推論を行い、随時ユーザの好みに合わせて属するグループを更新していく。

## 7 まとめと今後の課題

本研究では個人化した観光に対する推薦を実現するために、観光の体験を分析し趣味嗜好を推論するシステムを提案した。体験の分析では Who, Where, When, What の四要素に着目し、3つの洞察を考慮することでモデリングを行った。また、グループをモデルに加えることでコールドスタート問題に対応した。アプリケーションでは、提案手法のモデルを応用して推薦システムにした他、ユーザのフィードバックを適宜得ることによってより正確な推論を可能にした。これらのシステムによって「個」としての観光体験を見つけ出すことができる可能性が高い。

今後の課題としては、収束判断を明確にしつつ、精度を高めていくが必要になる。同時に観光体験を構成する四要素のうち、まだ時間を表す When に提案手法のモデルが対応していないため、観測変数として取り込まなくてはならない。また、今は写真に付いているタグを、行動を示している単語として

扱っているが、実際にそれが行動を表しているかは明確でない。  
それ故タグに換わる行動を示すものを見つけなくてはならない

謝辞 本研究の一部は総務省 SCOPE(172307001) による。

## 文 献

- [1] M. D. Hoffman and A. Gelman. The no-u-turn sampler: adaptively setting path lengths in hamiltonian monte carlo. *Journal of Machine Learning Research*, 15(1):1593–1623, 2014.
- [2] Y. Liu, T.-A. N. Pham, G. Cong, and Q. Yuan. An experimental evaluation of point-of-interest recommendation in location-based social networks. *Proceedings of the VLDB Endowment*, 10(10):1010–1021, 2017.
- [3] C. Song, Z. Qu, N. Blumm, and A.-L. Barabási. Limits of predictability in human mobility. *Science*, 327(5968):1018–1021, 2010.
- [4] B. Thomee, D. A. Shamma, G. Friedland, B. Elizalde, K. Ni, D. Poland, D. Borth, and L.-J. Li. Yfcc100m: The new data in multimedia research. *Communications of the ACM*, 59(2):64–73, 2016.
- [5] W. Wang, H. Yin, L. Chen, Y. Sun, S. Sadiq, and X. Zhou. Geo-sage: A geographical sparse additive generative model for spatial item recommendation. In *Proceedings of the 21th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 1255–1264. ACM, 2015.
- [6] H. Yin, B. Cui, X. Zhou, W. Wang, Z. Huang, and S. Sadiq. Joint modeling of user check-in behaviors for real-time point-of-interest recommendation. *ACM Transactions on Information Systems (TOIS)*, 35(2):11, 2016.
- [7] Q. Yuan, G. Cong, Z. Ma, A. Sun, and N. M. Thalmann. Who, where, when and what: discover spatio-temporal topics for twitter users. In *Proceedings of the 19th ACM SIGKDD international conference on Knowledge discovery and data mining*, pages 605–613. ACM, 2013.
- [8] Q. Yuan, G. Cong, K. Zhao, Z. Ma, and A. Sun. Who, where, when, and what: A nonparametric bayesian approach to context-aware recommendation and search for twitter users. *ACM Transactions on Information Systems (TOIS)*, 33(1):2, 2015.
- [9] C. Zhuang, Q. Ma, and M. Yoshikawa. Sns user classification and its application to obscure poi discovery. *Multimedia Tools and Applications*, 76(4):5461–5487, 2017.
- [10] 馬強. 観光の分散化と個人化の実現に向けたユーザ生成コンテンツの分析と利活用技術について. *システム/制御/情報*, 63(1):32–37, 2019.
- [11] 馬強 et al. 観光情報学の最前線-観光の分散化と個人化を促進する集合知活用情報技術. *情報処理*, 58(3):220–226, 2017.
- [12] 馬. 強. 木上 智貴. ジオソーシャル写真を用いた観光スポットの検知と景観評価.