

# 映画ポスターの色彩特徴を用いた映画推薦システム

菅谷 珠希<sup>†</sup>    奥    健太<sup>†</sup>

<sup>†</sup> 龍谷大学理工学部   〒 520-2194 滋賀県大津市瀬田大江町横谷 1-5  
E-mail: <sup>††</sup>t160377@mail.ryukoku.ac.jp, <sup>††</sup>okukenta@rins.ryukoku.ac.jp

あらまし 映画ポスター画像をジャンル別に見てみると、SF やミリタリー・戦争映画などは暗めのトーンで白と黒が多く使われていたり、アニメーションやコメディ映画などは明るめのトーンでカラフルな印象があったりするなど、その映画を印象付ける要素となっていることが分かる。本研究では、映画ポスター画像の色彩特徴が人の嗜好に影響を及ぼすかという点に着目し、映画ポスター画像の色彩特徴を用いた映画推薦システムを提案する。推薦システムの基本方式として、内容ベース推薦システム、協調フィルタリング、ハイブリッド型推薦システムなどが挙げられるが、本研究では、内容ベース推薦システムおよびハイブリッド型推薦システムを実装し、アイテム特徴として映画ポスターの色彩特徴を用いる。具体的な手法としては、まず OMDb API を用いて各映画のポスター画像を収集する。その収集した画像から色彩特徴を抽出し、それを基に特徴ベクトルを生成する。こうして得られた色彩特徴ベクトルを用いて内容ベース推薦システムおよびハイブリッド型推薦システムを実装し、精度の観点からその有用性を評価する。

キーワード 映画推薦, 内容ベース推薦, ハイブリッド型推薦, 色彩特徴

## 1. はじめに

映画推薦システムは、膨大な映画の中からユーザの嗜好に合った映画を推薦するシステムである。映画推薦システムの主な実現方式として、内容ベース推薦システム、協調フィルタリング、ハイブリッド型推薦システムが挙げられる。この中で、内容ベース推薦システムでは、映画の特徴表現が重要な課題となる [1]。映画の特徴としては、ジャンルや監督、俳優、あらすじから抽出されたテキスト情報などが用いられる。この映画の特徴表現が内容ベース推薦システムによる推薦精度に影響を及ぼす。

本研究では、新たな映画の特徴として映画ポスター画像の色彩特徴に着目する。映画ポスターを観察すると、SF 映画やミリタリー・戦争映画は、トーンが暗く、白と黒が多く使われている印象を受ける。一方で、アニメーションやコメディ映画は、トーンが明るく、カラフルな印象を受ける。このように、映画ポスターの色彩特徴はその映画の雰囲気や印象など感性的な側面を反映しているといえる。そこで、本研究では、映画ポスターの色彩特徴が人の映画に対する嗜好に影響を及ぼすかについて検証する。

具体的な検証方法は以下のとおりである。まず、MovieLens データセットを用いて映画のタイトルリストを取得する。そして取得した映画タイトルを基に OMDb API を用いて映画ポスター画像を収集する。そのポスター画像から HSV 値を抽出することで映画特徴ベクトルを生成し、映画に対するユーザの評価値履歴と併用して、内容ベース推薦システムとハイブリッド型推薦システムを実装する。ハイブリッド型推薦システムにおいては、色彩による映画特徴ベクトルを基に映画のクラスタリングを行い、クラスタごとのユーザの平均評価値履歴を基に作成したユーザ-映画クラスタ評価値行列を用いる。そして、そ

れぞれのシステムで、未評価の映画に対するユーザの予測評価値を確かめ、精度について比較、考察を行う。ここでのユーザ評価値履歴は、MovieLens データセットに含まれている複数のユーザが複数の映画を 5 段階で評価したデータを用いる。

## 2. 関連研究

内容ベース映画推薦システムにおいては、映画の特徴表現が重要となる [1]。高次の映画特徴としては、ジャンルや監督、俳優などが用いられる。これらは、コンテンツ作成者によって登録されたり、Web を介してタグによって与えられたりする。低次の映画特徴としては、映画コンテンツの映像の色や動作、明るさなどが挙げられる。これらは、ミゼンセーン (mise-en-scène) [2] 特徴とよばれ、動画ファイルから抽出される。

本研究では、映画ポスター画像の色彩特徴を用いた映画推薦システムを検討する。色彩に関する関連研究として菅波ら [3] の「映画ポスターの色彩が与える印象とジャンルの関係」という研究がある。この研究では、映画ポスターにおいて、コメディ映画はカラフルな色使い、ホラー映画は暗く重い色が多いことから、トーンの影響を受ける。一方、SF 映画は寒色、恋愛映画は赤色が多く使われていることから、色相の影響を受ける。ことが分かっている。

## 3. 定義

本稿において用いる記号を以下のとおり定義する：

$N$ : ユーザ数.

$M$ : アイテム (映画) 数.

$K$ : アイテム (映画) クラスタ数.

$u \in \{1, \dots, N\}$ : ユーザのインデックス.

$i \in \{1, \dots, M\}$ : アイテム (映画) のインデックス.

$k \in \{1, \dots, K\}$ : アイテム (映画) クラスタのインデックス.

$\mathbf{x}_i$ : アイテム (映画)  $i$  の特徴ベクトル.  
 $t_i$ : 映画  $i$  のタイトル.  
 $p_i$ : 映画  $i$  のポスター画像.  
 $\mathbf{h}_i$ : 映画  $i$  の色相特徴ベクトル.  
 $\mathbf{h}'_i$ : 正規化済みの色相特徴ベクトル.  
 $\mathbf{s}_i$ : 映画  $i$  の彩度特徴ベクトル.  
 $\mathbf{s}'_i$ : 正規化済みの彩度特徴ベクトル.  
 $\mathbf{v}_i$ : 映画  $i$  の明度特徴ベクトル.  
 $\mathbf{v}'_i$ : 正規化済みの明度特徴ベクトル.  
 $TR_u$ : ユーザ  $u$  の学習データセット.  
 $r_{ui}$ : ユーザ  $u$  のアイテム (映画)  $i$  に対する評価値.  
 $\hat{r}_{ui}$ :  $r_{ui}$  に対する予測評価値.  
 $\mathbf{R}$ : ユーザ-アイテム (映画) 評価値行列.  
 $\mathcal{R}$ : ユーザ-アイテム (映画) クラスタ評価値行列.  
 $I_u$ : ユーザ  $u$  の評価済みアイテム (映画) 集合.  
 $I_k$ : クラスタ  $k$  に含まれるアイテム (映画) 集合.

## 4. 前 提

### 4.1 内容ベース推薦システム

内容ベース推薦システムでは、与えられたユーザ  $u$  の評価履歴データを基に、未評価のアイテムへの評価値を予測する [4] [5]. まず、ユーザ  $u$  の評価履歴データから学習データセット  $TR_u$  を作成する. 学習データセット  $TR_u$  は  $\langle \mathbf{x}_i, r_{ui} \rangle$  の対の集合である. ここで、 $\mathbf{x}_i$  はアイテム  $i$  の特徴ベクトルを、 $r_{ui}$  はユーザ  $u$  がアイテム  $i$  に対して与えた評価値を表す. 学習データセット  $TR_u$  を基に、教師あり学習により学習モデル—ユーザプロファイル—を生成し、生成された学習モデルを用いて未評価のアイテムへの予測評価値  $\hat{r}_{ui}$  を求める. なお、特徴ベクトル  $\mathbf{x}_i$  は、映画を例にすると、映画のジャンルやメタデータ (年代や映画監督、出演俳優など)、タグ、レビューから抽出された単語集合 (Bag of Words) などから与えられる.

### 4.2 協調フィルタリング

協調フィルタリングでは、与えられた評価値行列  $\mathbf{R}$  を基に、未評価のアイテムへの評価値を予測する [6]. ここで、評価値行列  $\mathbf{R}$  は  $N$  人のユーザと  $M$  個のアイテムとの関係を表した行列であり、 $N \times M$  行列となる. 行列の要素は  $r_{ui}$  とし、ユーザ  $u$  がアイテム  $i$  に与えた評価値を表す.

協調フィルタリングには、近傍ベース手法とモデルベース手法がある. 近傍ベース手法では、評価値行列  $\mathbf{R}$  から類似ユーザまたは類似アイテムを選定し、これらの類似ユーザまたは類似アイテムの評価値を基に対象ユーザの未評価アイテムへの評価値を予測する. モデルベース手法では、評価値行列  $\mathbf{R}$  における観測値を基にモデルを学習し、欠損値に入る予測評価値  $\hat{r}_{ui}$  を求める. ここで、モデルとして非負値行列因子分解 (NMF) を用いた手法が優れた推薦精度を示すことが知られている [7].

NMF では、次式で表されるように、評価値行列  $\mathbf{R} = [r_{ui}]_{N \times M}$  に近似する潜在特徴行列  $\mathbf{P} = [p_{ud}]_{N \times D}$ ,  $\mathbf{Q} = [q_{id}]_{M \times D}$  を見つける:

$$\mathbf{R} \approx \mathbf{P} \times \mathbf{Q}^T \quad (1)$$

ここで、 $\mathbf{P}$  はユーザに関する潜在特徴行列、 $\mathbf{Q}$  はアイテムに関する潜在特徴行列であり、それぞれユーザ、アイテムを  $d$  次元の潜在特徴ベクトルで表現する.  $d$  は経験的あるいは実験的に決定される.

最終的に、学習により収束した  $\mathbf{P}, \mathbf{Q}$  を用いて、次式より予測評価値行列  $\hat{\mathbf{R}} = [\hat{r}_{ui}]_{N \times M}$  を得る:

$$\hat{\mathbf{R}} = \mathbf{P} \times \mathbf{Q}^T \quad (2)$$

### 4.3 ハイブリッド型推薦システム

ハイブリッド型推薦システムは、内容ベース推薦システムと協調フィルタリングを組み合わせた推薦システムである [4]. ハイブリッド型推薦システムとしては、多くのアプローチが提案されているが [8]、本研究ではメタレベルハイブリッドを用いる.

メタレベルハイブリッドでは、多くの場合、内容ベース推薦システムと協調フィルタリングが組み合わせられる. 協調フィルタリングにおいては、あらかじめアイテム特徴に基づき類似アイテムをクラスタリングしておき、ユーザとアイテムクラスタの関係を表した評価値行列を用いる. つまり、ユーザ-アイテムの評価値行列  $\mathbf{R}$  ではなく、ユーザ-アイテムクラスタ評価値行列  $\mathcal{R}$  に対して協調フィルタリングを適用する.

## 5. ポスター画像に基づく映画特徴化

本研究では、映画ポスター画像から抽出した色彩情報を基に、映画を特徴化する. 本章では、ポスター画像に基づく映画特徴化の手法について述べる. 映画特徴化手法の流れは下記のとおりである:

- (1) 映画データベースから映画のタイトルリストを取得.
- (2) OMDb API による映画ポスター画像の収集.
- (3) 映画ポスター画像の色彩情報に基づく特徴ベクトル化.

以下、それぞれ詳細に説明する.

### 5.1 映画タイトルリストの取得

MovieLens<sup>(注1)</sup> や IMDb<sup>(注2)</sup> など、研究用に多くの映画データセットが公開されている. ここでは、これらの映画データセットから映画タイトルのリストを取得する. 取得する属性には、映画 ID および映画タイトルが含まれるものとする. 映画  $i$  について取得した映画タイトルを  $t_i$  と表す.

### 5.2 ポスター画像の収集

前節で取得した映画タイトルに対応するポスター画像を収集する. 映画のポスター画像の取得には、OMDb (The Open Movie Database) API<sup>(注3)</sup> を使用する. OMDb API は映画情報を取得するために提供されている API であり、映画情報の中にポスター画像も含まれている. OMDb API による映画情報の検索には、映画 ID (IMDb 上での映画 ID) による方法と映画タイトルによる方法がある. ここでは、映画タイトルによりポスター画像を収集する. 映画  $i$  のポスター画像を  $p_i$  と表す.

(注1): <https://grouplens.org/datasets/movielens/>

(注2): <https://www.imdb.com/interfaces/>

(注3): <http://www.omdbapi.com/>




図 1 色相スケール

表 1 正規化済みの色彩特徴ベクトルの例

映画 ID	色相 1	色相 2	色相 3	色相 4	色相 5	色相 6
1	0.223	0.0742	0.0682	0.327	0.0739	0.0670
2	0.380	0.112	0.00477	0.0101	0.0176	0.0518
3	0.0819	0.00524	0.00560	0.561	0.00270	0.00173

### 5.3 映画の特徴ベクトル化

取得したポスター画像  $p_i$  を基に、映画  $i$  の特徴ベクトル  $\mathbf{x}_i$  を算出する。本研究では、ポスター画像の色彩情報として HSV 色空間に着目する。

HSV 色空間は、色相 (Hue)、彩度 (Saturation)、明度 (Value) の 3 種類の成分から構成される。色相は、赤やオレンジ、緑、青などの具体的な色を定義する要素であり、 $0^\circ$ – $360^\circ$  の範囲で表される。彩度は、色の鮮やかさや濃さを表す要素であり  $0\%$ – $100\%$  で表される。明度は、色の明るさ、暗さを定義する要素であり、 $0\%$ – $100\%$  で表される。

色相を例に取り上げると、図 1 の色相スケールの破線で示しているように、 $60^\circ$  ごとの六つの区分に分割する。つまり、 $330^\circ$ – $360^\circ$  または  $0^\circ$ – $30^\circ$  の範囲を色相区分 1、 $30^\circ$ – $90^\circ$  の範囲を色相区分 2 というように、色相区分 1 から色相区分 6 に分割する。

次に、ポスター画像  $p_i$  について、各色相区分に属する画素数を取得する。ここで、ポスター画像  $p_i$  のうち色相区分  $j$  に属する画素数を  $h_i^j$  と表す。この  $h_i^j$  を要素としたベクトル  $\mathbf{h}_i = (h_i^1, h_i^2, h_i^3, h_i^4, h_i^5, h_i^6)$  を作成する。

ただし、ベクトルの各要素は最大値が 1、最小値が 0 になるように正規化しておく。正規化済みの色相区分  $j$  の要素  $h_i^{j'}$  は次式により求める：

$$h_i^{j'} = \frac{h_i^j - h_{\min}^j}{h_{\max}^j - h_{\min}^j} \quad (3)$$

ここで、 $h_{\max}^j$  は色相区分  $j$  のすべてのデータの最大値、 $h_{\min}^j$  は色相区分  $j$  のすべてのデータの最小値を表す。最終的に、正規化済みの色相特徴ベクトル  $\mathbf{h}_i'$  を映画  $i$  の特徴ベクトルとする。

表 1 にその一例を示す。例えば、映画 ID が 3 のアイテムは、色相 4 の値が最も大きいことから、水色の部分を多く占めるポスターであることがわかる。

つづいて、彩度および明度に関する特徴量も取得する。これらは  $20\%$  ごとの 5 つの区分に分割する。色相と同様の方式で、各区分に属する画素数を取得する。彩度の場合、ポスター画像

$p_i$  のうち彩度区分  $j$  に属する画素数を  $s_i^j$  と表す。この  $s_i^j$  を要素としたベクトル  $\mathbf{s}_i = (s_i^1, s_i^2, s_i^3, s_i^4, s_i^5)$  を作成する。明度の場合は、ポスター画像  $p_i$  のうち明度区分  $j$  に属する画素数を  $v_i^j$  と表す。この  $v_i^j$  を要素としたベクトル  $\mathbf{v}_i = (v_i^1, v_i^2, v_i^3, v_i^4, v_i^5)$  を作成する。これらのベクトルの各要素も、式 (3) と同様に、最大値が 1、最小値が 0 になるように正規化する。正規化済みの特徴ベクトル  $\mathbf{s}_i'$ 、 $\mathbf{v}_i'$  を、それぞれ映画  $i$  の彩度特徴ベクトル、明度特徴ベクトルとする。

## 6. 映画推薦システムへの色彩特徴の適用

### 6.1 内容ベース推薦システムへの適用

4.1 節で述べた内容ベース推薦システムに色彩特徴を適用する。ユーザ  $u$  の学習データセット  $TR_u$  は  $\langle \mathbf{x}_i, r_{ui} \rangle$  とする。このとき、映画  $i$  の特徴ベクトル  $\mathbf{x}_i$  は、5.3 節で求めた色彩特徴ベクトルに相当する。また、評価値  $r_{ui}$  はユーザ  $u$  の映画  $i$  に対する評価値である。評価値の与え方としては、5 段階評価値  $r_{ui} \in \{1, 2, 3, 4, 5\}$  や 2 値評価値  $r_{ui} \in \{-1, +1\}$  などを想定する。実際には、利用できるデータセットや適用する機械学習手法により決定する。

### 6.2 ハイブリッド型推薦システムへの適用

4.3 節で述べたように、本研究ではメタレベルハイブリッドに色彩特徴を適用する。事前に映画集合を映画の特徴ベクトル  $\mathbf{x}_i$  を基にクラスタリングしておく。そして、得られた映画クラスタを用いて、ユーザ-映画クラスタ評価値行列  $\mathbf{R}$  を作成する。ここで、評価値行列  $\mathbf{R}$  は  $N$  人のユーザと  $K$  個の映画クラスタとの関係を表した行列であり、 $N \times K$  行列とする。

評価値行列  $\mathbf{R}$  の作成過程は以下のとおりである：

- (1)  $M$  個の映画に対し、映画の特徴ベクトル  $\mathbf{x}_i$  に基づきクラスタリングを実行する。
- (2) クラスタリングにより得られたクラスタ  $k$  に含まれるアイテム集合を  $I_k$  とする。
- (3) 集約関数  $r(u, k)$  によりユーザ  $u$  のアイテム集合  $I_k$  に対する評価値を集約する。
- (4)  $r(u, k)$  を行列の要素とした評価値行列  $\mathbf{R}$  を作成する。ここで、集約関数  $r(u, k)$  は次式のとおりに定義する：

$$r(u, k) = \begin{cases} \frac{1}{|I_u \cap I_k|} \sum_{i \in I_u \cap I_k} r_{ui} & (|I_u \cap I_k| > 0) \\ 0 & (\text{otherwise}) \end{cases} \quad (4)$$

つまり、ユーザ  $u$  のクラスタ  $k$  に対する評価値は、クラスタ  $k$  内のアイテム集合のうち、ユーザ  $u$  により評価済みのアイテム集合を対象に求められた平均評価値となる。クラスタ  $k$  内に評価済みアイテム集合が存在しない場合は、クラスタ  $k$  に対する評価値は 0 とする。

## 7. 評価

映画推薦システムに色彩特徴を適用することによる有用性を確かめるために評価実験を行った。7.1 節で内容ベース推薦システムに色彩特徴を適用したときの有用性を、7.2 節でハイブリッド型推薦システムに色彩特徴を適用したときの有用性を、それぞれ評価する。

## 7.1 内容ベース推薦システムにおける評価

本節では、6.1 節で述べたとおり、内容ベース推薦システムに色彩特徴を適用したときの有用性を評価する。

### 7.1.1 データセット

映画データセットとして、MovieLens100K<sup>(注4)</sup>を用いる。このデータセットには、1997 年 9 月から 1998 年 4 月の間に取得された 1,682 本の映画データと、943 人のユーザによる 100,000 もの評価値データが含まれている。ここでの評価値データは、各ユーザが、少なくとも 20 本以上の映画に対して評価値を与えているものとする。

ポスター画像は、5.2 節で述べたとおり、MovieLens のタイトルリストを基に、OMDb API を用いて取得する。ただし、ポスター画像を取得する際、OMDb にポスター画像が存在しなかった映画は除外した。その結果、1,491 枚のポスター画像が取得できたので、これらを対象の映画とする。

評価値は {1, 2, 3, 4, 5} の 5 段階評価により与えられている。ただし、本実験では後述する 2 クラス分類手法を適用することを想定し、評価値を正事例と負事例の 2 クラスに分割する。評価値 {4, 5} が与えられたデータを正事例、評価値 {1, 2} が与えられたデータを負事例として用いる。なお、評価値 3 が与えられたデータは用いないものとする。このとき、両事例においてそれぞれ少なくとも 10 件以上の評価値を与えているユーザのみを対象とした。その結果、対象のユーザ数は 341 人、全評価値データ数は 33,388 となった。また、ユーザごとの評価値数は、最小値が 20、最大値が 460、中央値は 86 となった。

そして、ユーザごとのデータを対象に、無作為に選んだ 70% を学習データ、残りの 30% をテストデータとして分割した。

### 7.1.2 実験方法

内容ベース推薦システムの実装には、2 クラス分類手法である SVM (サポートベクタマシン) を用いる。また、SVM のカーネルには RBF (Radial Basis Function) カーネルを用いる。SVM のパラメタである  $C$  および  $\gamma$  は、学習データに対するグリッドサーチにより最適値を求めた。

各ユーザの学習データを基に、SVM によりユーザ個別の学習モデルを構築し、その学習モデルを用いて各ユーザのテストデータに対して正事例/負事例を予測する。

予測後、テストデータに含まれる正事例/負事例を正解データとし、その正解と一致した数の割合から正解率を算出する。具体的に、正解率は次式で算出される：

$$\text{正解率} = \frac{\text{正解データ数}}{\text{テストデータ数}} \quad (5)$$

正解率はユーザごとに算出し、全ユーザに対する平均正解率を評価指標とする。

### 7.1.3 比較対象

以下に示す映画特徴を比較対象とする：

ジャンルのみ (**G**) (ベースライン)： MovieLens に含まれる 18 種類のジャンル (アクションやラブストーリー、ホラーなど) を用いた。各ジャンルは各特徴次元に対応する。ここで、

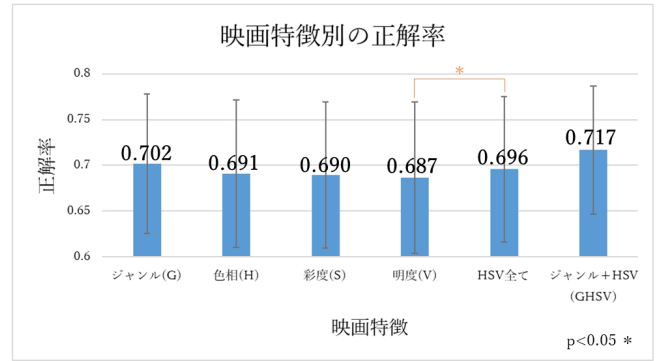


図2 内容ベース推薦システムによる正解率の比較  
正解率に有意差があった対には、\* を示している。

該当するジャンルの特徴次元は 1 に、該当しないジャンルの特徴次元は 0 とする。すなわち、映画の特徴ベクトル  $\mathbf{x}_i$  は、ジャンルの該当/非該当を表す 18 次元の特徴ベクトルとなる。

色相のみ (**H**)： 5.3 節で述べた色彩特徴のうち色相特徴のみを用いた。すなわち、 $\mathbf{x}_i = \mathbf{h}_i$  となる。 $\mathbf{x}_i$  の特徴次元数は 6 次元となる。

彩度のみ (**S**)： 同様に、彩度特徴のみを用いた。すなわち、 $\mathbf{x}_i = \mathbf{s}_i$  となる。 $\mathbf{x}_i$  の特徴次元数は 5 次元となる。

明度のみ (**V**)： 同様に、明度特徴のみを用いた。すなわち、 $\mathbf{x}_i = \mathbf{v}_i$  となる。 $\mathbf{x}_i$  の特徴次元数は 5 次元となる。

色相+彩度+明度 (**HSV**)： 上記の **H**, **S**, **V** を結合した特徴である。すなわち、 $\mathbf{x}_i = (\mathbf{h}_i, \mathbf{s}_i, \mathbf{v}_i)$  となる。特徴次元数は 16 次元となる。

ジャンル+色相+彩度+明度 (**GHSV**)： 上記の **G** と **HSV** を結合した特徴である。すなわち、 $\mathbf{x}_i$  は 34 次元の特徴ベクトルとなる。

### 7.1.4 結果

図2に、内容ベース推薦システムによる正解率を示す。図の横軸は学習に用いた映画特徴、縦軸は正解率を示す。映画特徴は、**G**, **H**, **S**, **V**, **HSV**, **GHSV** とする。

色彩特徴のみ (**H**, **S**, **V**, **HSV**) に着目すると、各特徴を単体で用いた **H**, **S**, **V** よりも、すべての色彩特徴を用いた **HSV** の方が正解率が高かった。このことから、**HSV** をすべて用いることが、精度向上に寄与するといえる。

また、ベースラインであるジャンル (**G**) と比較すると、色彩特徴のみを用いた **HSV** は、**G** に比べ正解率が下回った。一方で、ジャンルと色彩特徴の両方を用いた **GHSV** では、**G** と比べ、わずかながら正解率が向上した。これらの間には有意差はみられなかったものの、既存の映画特徴に対して色彩特徴を加味することは、精度向上に寄与することが示唆された。

## 7.2 ハイブリッド型推薦システムにおける評価

本節では、6.2 節で述べたハイブリッド型推薦システムに色彩特徴を適用したときの有用性を評価する。

### 7.2.1 データセット

本実験においても、7.1.1 項で用いた MovieLens100K データセットを用いる。この MovieLens100K データセットに含ま

(注4) : <https://grouplens.org/datasets/movielens/100k/>

れる映画集合を対象に、6.2 節で述べた手法により、色彩特徴に基づくクラスタリングを行う。本実験では、クラスタリング手法として階層的クラスタリングを用いた。具体的には、群平均法を用い、距離の定義にはキャンベラ距離を採用した。クラスタリングの結果、1,491 枚のポスター画像は 157 のクラスタに分類された。本実験では、この映画クラスタを適用したユーザ-映画クラスタ評価値行列と、比較対象として元のユーザ-映画評価値行列をデータセットとして用いる。

ここで、内容ベース推薦システムにおける実験条件と合わせるため、評価値行列に含まれるユーザを 7.1.1 項で示したユーザと同一にした。したがって、ユーザ-映画クラスタ評価値行列、ユーザ-映画評価値行列、共にユーザ数は 341 名とした。ただし、評価値は 5 段階評価のまま用いるものとする。また、ユーザ数を減らしたことにより、対象となる映画数も減少したため、ユーザ-映画クラスタ評価値に関しては、 $341 \times 139$  の行列、ユーザ-映画評価値に関しては  $341 \times 1023$  の行列となった。

これら二つの行列に対して、評価値行列に含まれる全評価値のうち無作為に 30% を抜き出し、抜き出した評価値を欠損値とした評価値行列を学習データとし、欠損値に対応する元の評価値をテストデータとして実験を行った。

### 7.2.2 実験方法

学習データである評価値行列に対し、4.2 節で述べた NMF を実行する。そして、NMF により得られた予測評価値とテストデータに含まれる評価値との差分を求める。

具体的には、次式で定義される平均絶対誤差 MAE を算出する：

$$MAE = \frac{1}{|T|} \sum_{u,i \in T} |\hat{r}_{ui} - r_{ui}| \quad (6)$$

ここで、 $T$  はテストデータ中の評価値集合であり、 $|T|$  はその評価値数を表す。 $r_{ui}$  はユーザ  $u$  がアイテム  $i$  に対して与えた実評価値であり、 $\hat{r}_{ui}$  は予測評価値である。MAE が小さいほど予測精度が高いことを示す。

なお、NMF を適用する際の潜在特徴行列の次元数  $d$  の決定については、7.2.4 項で述べる。

### 7.2.3 比較対象

以下に示す評価値行列を比較対象とする：

ユーザ-映画評価値行列 (**M**) (ベースライン)： 7.2.1 項で述べた  $341 \times 1023$  のユーザ-映画評価値行列。

ユーザ-映画クラスタ評価値行列 (**C**)： 7.2.1 項で述べた  $341 \times 139$  のユーザ-映画クラスタ評価値行列。

### 7.2.4 パラメタ分析

NMF における潜在特徴行列の次元数  $d$  を実験的に決定する。本実験では、 $d$  を  $[1, 30]$  の範囲で変化させたときの MAE を比較する。

図 3 は  $d$  の違いによる MAE の変化を示したものである。図より、ユーザ-映画評価値行列においては  $d = 12$  のとき、ユーザ-映画クラスタ評価値行列においては  $d = 3$  のとき、それぞれ MAE が最小値を示した。したがって、以降の実験では各評価値行列において、これらの  $d$  を用いる。




図 3 各行列による特徴次元ごとの MAE




図 4 ハイブリッド型推薦システムによる各データの誤差比較

### 7.2.5 結果

図 4 に、各評価値行列を対象としたときの MAE を示す。図の横軸は対象とした評価値行列 **M**、**C** を、縦軸は MAE を示す。

図のとおり、**M** における MAE は 0.0765、**C** における MAE は 0.198 となった。この結果から、元のユーザ-映画評価値行列を用いた方が MAE が小さいことが分かる。したがって、ハイブリッド型推薦システムにおいて色彩特徴を用いることの有用性は示されなかった。

今後は、クラスタリング方法等、ハイブリッド型推薦システムへの色彩特徴の導入の仕方をより厳密に検討していく必要があるといえる。

## 8. おわりに

本研究では、映画ポスター画像の色彩特徴が人の嗜好に影響を及ぼすかという点に着目し、映画ポスター画像の色彩特徴を用いた映画推薦システムを提案した。推薦システムとして、内容ベース推薦システムおよびハイブリッド型推薦システムを実装し、アイテム特徴として映画ポスターの色彩特徴を用いた。

その結果、内容ベース推薦システムにおいては、アイテム特徴として、色相、彩度、明度 (**H,S,V**) をそれぞれ単独で用いたときと比べ、すべて用いた **HSV** を適用した方が精度が高かったことを確認した。また、既存の映画特徴であるジャンル (**G**) と比較した際には、**G** に映画ポスターの色彩特徴を加味したと



きに、わずかに精度が向上したことから、アイテム特徴として色彩情報を加味することが、精度向上に寄与すると示唆された。

一方で、ハイブリッド型推薦システムにおいては、色彩特徴を用いることの有用性は示されなかった。そのため、クラスタリング方法等、ハイブリッド型推薦システムへの色彩特徴の導入の仕方をより厳密に検討していく必要があるといえる。

今後は、内容ベース推薦システムと、ハイブリッド型推薦システムの使用条件を統一し、両システムの精度の比較を行うことを検討する。また、アイテム特徴として色彩特徴だけでなく、映画ポスター内の人物の認識やレイアウトなども考慮していくことで、精度がどのように変化するのか比較、検討していく予定である。

## 謝 辞

本研究は JSPS 科研費 19K12567 の助成を受けたものです。ここに記して謝意を表します。

## 文 献

- [1] Mehdi Elahi, Yashar Deldjoo, Farshad Bakhshandegan Moghaddam, Leonardo Cella, Stefano Cereda, and Paolo

- Cremonesi. Exploring the Semantic Gap for Movie Recommendations. In *[RecSys2017]Proceedings of the 11th ACM conference on Recommender systems*, pp. 326–330, 2017.
- [2] Yashar Deldjoo, Mehdi Elahi, Paolo Cremonesi, Franca Garzotto, Pietro Piazzolla, and Massimo Quadrana. Content-Based Video Recommendation System Based on Stylistic Visual Features. *Journal on Data Semantics*, Vol. 5, No. 2, pp. 99–113, 2016.
- [3] 菅波航, 有光翔理, 斎藤美穂. 映画ポスターの色彩が与える印象とジャンルの関係. *日本色彩学会誌*, Vol. 37, No. 3, pp. 336–337, 2013.
- [4] F. Ricci, L. Rokach, B. Shapira, and P. B. Kantor. *Recommender Systems Handbook*. Springer, 2011.
- [5] Iván Cantador, Alejandro Bellogín, and David Vallet. Content-based recommendation in social tagging systems. In *[RecSys2010]Proceedings of the 4th ACM conference on Recommender systems*, p. 237, 2010.
- [6] Jonathan L. Herlocker, Joseph A. Konstan, Loren G. Terveen, and John T. Riedl. Evaluating collaborative filtering recommender systems. *[ACM]ACM Transactions on Information Systems*, Vol. 22, No. 1, pp. 5–53, 2004.
- [7] Yehuda Koren, Robert Bell, and Chris Volinsky. Matrix Factorization Techniques for Recommender Systems. *IEEE Computer*, Vol. 42, No. 8, pp. 30–37, 2009.
- [8] Robin Burke. Hybrid Recommender Systems: Survey and Experiments. *User Modeling and User-Adapted Interaction*, Vol. 12, No. 4, pp. 331–370, 2002.